هندسة الهارنيس الموحد والوكيل المحاسبي الذاتي للأعمال الصغيرة في الأسواق العربية: دراسة معمارية واستراتيجية لتطوير منظومة «وكيل»

مرجع معماري واستراتيجي شامل لتصميم الهارنيس، وبوابة النماذج الموحدة (BYOK)، والذاكرة ذاتية التطور، والتحكم الكامل في الواجهة، ومتطلبات التشغيل الميداني في الأسواق العربية

تقدم هذه الدراسة الهندسية والاستراتيجية خارطة التطوير المتكاملة لمنظومة «وكيل» (Wakil AI Agent Harness) بهدف تحويل أي نموذج ذكاء اصطناعي إلى موظف محاسبي وتشغيلي فائق السرعة والدقة يدير العمليات اليومية للصيدليات، ومحلات العطارة، والسوبر ماركت، والنوادي الرياضية (الجيمات) دون الحاجة إلى تعقيدات أنظمة تخطيط موارد المؤسسات التقليدية (ERP).

المحاور المعمارية والتشغيلية الرئيسية في الدراسة

المحور الهندسي	التركيز التحليلي والتطبيقي	المرجعيات القياسية المدروسة
هندسة الهارنيس وبوابة BYOK	دعم أي Base URL وAPI Key عبر البروتوكولات الأربعة وفصل مخرجات الأدوات	Pi Coding Agent (`pi-ai`), OpenCode, DeepSeek API, Inspect AI
السرعة الفائقة والكاش	خفض زمن الاستجابة المدرك إلى أقل من ثانية عبر التوجيه الهجين والجلب الاستباقي	DeepSeek V3.2 Context Caching, OpenAI Prompt Caching, Agentic Routing
الذاكرة الحية والتعلم الذاتي	بناء ذاكرة خماسية الطبقات (`BUSINESS_DNA`, `LEXICON_GRAPH`, `SKILLS`) تتطور مع الشغل	ChatGPT 4-Layer Memory, Claude Memory Tools, Pi `AGENTS.md` & `SKILL.md`
تحكم الموديل الكامل والـ UX	تفكيك المهام المركبة، وتشكيل الواجهة ديناميكياً، ومصفوفة الاعتماد البشري (HITL)	AG-UI Protocol, Claude Artifacts, AI UX Playground HITL Patterns
تعميق السوق العربي (4 قطاعات)	معالجة التجزئة والصلاحيات، والبيع العكسي بالوزن، وكشكول الشكك، والتجميد والـ PT	فارماكير، ميدكاكير، ديكسيف للعطارة، البدر للمبيعات، سجل ERP، جيماوي

تصنيف الوثيقة: دراسة معمارية واستراتيجية تنفيذية

النطاق القطاعي: الصيدليات، العطارة، السوبر ماركت، الجيمات

تاريخ الإصدار: أكتوبر 2026

1. التحول من البرمجيات المحاسبية التقليدية إلى معمارية الموظف الذكي المدمج

يشهد قطاع البرمجيات الموجهة للشركات الصغيرة والمتوسطة تحولاً هيكلياً يعيد تعريف العلاقة بين صاحب النشاط التجاري والنظام الرقمي. ففي حين تعتمد المؤسسات الكبرى على أنظمة تخطيط موارد المؤسسات (ERP) المعقدة التي تتطلب فرقاً محاسبية متخصصة وتدريباً طويلاً، تعاني المنشآت الصغيرة في الأسواق العربية — مثل الصيدليات المستقلة، ومحلات العطارة والمحامص، والسوبر ماركت والبقالات، والنوادي الرياضية (الجيمات) — من فجوة تشغيلية حادة. تكشف الممارسات اليومية أن أغلبية هذه الأنشطة تظل حبيسة «الورقة والقلم» وكشاكيل الحسابات اليدوية، ليس بسبب غياب البرامج المحاسبية في السوق، بل لأن تلك البرامج صُممت بعقلية المحاسب القانوني ومهندس قواعد البيانات، لا بعقلية التاجر الذي يقف أمام عشرات الزبائن في وقت الذروة.

إن الفرضية الاستراتيجية التي يقوم عليها تطوير منظومة «وكيل» تتمثل في إلغاء حاجة صاحب العمل إلى تعلم برنامج جديد من الأساس. بدلاً من تقديم شاشات إدخال معقدة وقوائم منسدلة وشجرة حسابات جامدة، يقدم النظام «موظفاً محاسبياً وتشغيلياً فائق الذكاء» يمتلك نظامه الداخلي الخاص الذي يديره بنفسه خلف الكواليس. يتحدث صاحب العمل أو الكاشير مع هذا الموظف باللهجة العامية الطبيعية أو عبر أوامر صوتية ونصية سريعة (مثل: «بعت بـ 15 جنيه كمون، وخدت 500 جنيه من حساب الحاج سعيد، وكابتن محمود سجل اشتراك سنوي النهارده»)، ويتولى الهارنيس (Agent Harness) ترجمة هذه الوقائع اليومية إلى قيود مالية، وحركات مخزنية، وتحديثات أرصدة، وتنبيهات تشغيلية دقيقة وموثقة.

غير أن تحويل هذا التصور إلى نظام إنتاجي موثوق يتطلب الفصل الصارم بين «النموذج اللغوي» (LLM) وبين «الهارنيس التشغيلي» (Agent Harness). فالنموذج اللغوي وحده — مهما بلغت قوته — يظل محركاً احتمالياً لتوليد النصوص، يفتقر إلى الذاكرة الدائمة، ولا يملك قدرة ذاتية على ضمان عدم تكرار القيود المالية، كما أنه عرضة للهلوسة الحسابية ونسيان السياق عند امتلاء نافذة المحادثة. وهنا تبرز أهمية هندسة الهارنيس بوصفها البنية التحتية غير النموذجية (The Non-Model Infrastructure) التي تحول أي نموذج ذكاء اصطناعي — سواء كان نموذجاً سحابياً رائداً أو نموذجاً مفتوح المصدر يعمل عبر مفتاح خاص (BYOK) — إلى موظف منضبط، فائق السرعة، يتذكر تفاصيل العمل، ويطور مهاراته وأدواته باستمرار، ويتحكم في واجهة التطبيق بالكامل ضمن حواجز أمان حتمية.

البعد التشغيلي	أنظمة المحاسبة ونقاط البيع التقليدية (ERP / POS)	الشات بوت التقليدي المربوط بقاعدة بيانات	معمارية هارنيس «وكيل» الذاتية (Wakil Agent Harness)
نموذج التفاعل الأساسي	إدخال يدوي عبر عشرات الشاشات والحقول الإلزامية	محادثة نصية حرة تفتقر إلى التحكم في الواجهة والحالة	محادثة تشغيلية مقترنة ببطاقات تفاعلية وتحكم كامل في التطبيق
الاعتماد على الموديل	لا يوجد ذكاء اصطناعي أو يقتصر على تقارير إحصائية	مربوط بمزود واحد مع برومبت متضخم وعرضة للهلوسة	مستقل عن الموديل (BYOK) يدعم أي Base URL مع توجيه هجين
إدارة الحسابات والأرقام	معادلات برمجية صلبة تتطلب إدخالاً مسبقاً لكل صنف	يترك الحساب للنموذج اللغوي مما يسبب أخطاء مالية	محرك حسابات عشري حتمي (Decimal Engine) يحسب خارج الموديل
الذاكرة والتعلم المستمر	إعدادات ثابتة لا تتغير إلا بتدخل المبرمج	نافذة سياق مؤقتة تضيع بانتهاء الجلسة أو RAG بسيط	ذاكرة خماسية الطبقات تتعلم قوانين المحل ومفرداته وتطور مهاراتها
معالجة المهام المركبة	المستخدم ينفذ كل خطوة في شاشة منفصلة يدوياً	يفشل عند جمع عدة طلبات في جملة واحدة	تفكيك تلقائي للمهمة إلى قائمة خطوات (DAG) وتنفيذ متتابع موثق
الأمان والاعتماد البشري	صلاحيات شاشات تقليدية جامدة	إما تنفيذ عشوائي خطر أو سؤال المستخدم عن كل صغيرة	مصفوفة مخاطر (R0-R4) مع بطاقات اعتماد تعرض الفروقات بدقة

تُظهر المقارنة المعمارية في الجدول أعلاه أن القيمة التنافسية لمنظومة «وكيل» لا تكمن في امتلاك نموذج لغوي خاص، بل في بناء أذكى وأسرع «هارنيس محاسبي وتشغيلي» في السوق العربي. فبينما تقدم منصات عالمية مثل Shopify Sidekick مساعداً للتجارة الإلكترونية، وتوفر أنظمة إقليمية مثل دفترة (Daftra) وLoyverse وPosMasr إما وحدات محاسبية تقليدية أو ربطاً للقراءة فقط عبر MCP، فإن هارنيس «وكيل» ينفرد بكونه المحرك التنفيذي الذي يدير دورة العمل كاملة من الفهم اللغوي باللهجة المحلية إلى القيد المالي الحتمي وتشكيل الواجهة ديناميكياً.

2. استراتيجية التطوير التراكمي لمنظومة «وكيل» دون إعادة البناء من الصفر

تمتلك منظومة «وكيل» في تصميمها المرجعي الحالي أساساً هندسياً متيناً يرتكز على نواة معيارية (Modular Monolith)، وقاعدة بيانات معاملاتية (PostgreSQL) مدعومة بسياسات عزل الصفوف (PostgreSQL Row-Level Security)، ونمط صندوق الصادر المعاملاتي (Transactional Outbox)، ومفاتيح منع التكرار (Idempotent Requests على غرار Stripe)، وسجل أحداث غير قابل للمحو الصامت، ومصفوفة مخاطر من خمس درجات (R0 إلى R4). إن الخطأ الاستراتيجي الأكبر الذي قد يقع فيه أي فريق هندسي في هذه المرحلة هو هدم هذه البنية لإعادة كتابتها من الصفر تحت مسمى «التحول إلى إيجنت».

تقتضي الحكمة الهندسية تطبيق نمط التطوير التراكمي بالاحتواء التدريجي (Strangler Fig & Sidecar Harness Pattern)، حيث تبقى طبقات المجال الأساسية (Domain Modules: Ledger, Inventory, Memberships, Parties, Cashflow, Audit) كما هي دون المساس بثوابتها المالية (Business Invariants)، بينما يتم ترقية طبقة `Agent Runtime` و`Model Gateway` و`Typed Tool Registry` لتصبح هي الهارنيس الذكي الجديد. بمعنى آخر، فإن قواعد البيانات، وقيود عدم التكرار، ومحرك السياسات (Policy Engine) التي تم بناؤها بالفعل تمثل «الجهاز العصبي اللاإرادي» الذي يمنع الكوارث المالية، بينما يمثل الهارنيس الجديد «القشرة الدماغية والذاكرة الحية» التي تمنح الموديل القدرة على الفهم والتخطيط والتعلم والتحكم في الواجهة.

المكون في معمارية «وكيل» الحالية	الوضع الراهن في التصميم الأساسي	الترقية المعمارية المطلوبة داخل الهارنيس (بدون هدم)	الأثر المباشر على المنتج والمستخدم
بوابة النماذج (Model Gateway)	طبقة توجيه داخلية لمزودات محددة سلفاً	ترقيتها إلى محول قياسي رباعي البروتوكولات يدعم BYOK وأي Base URL مع فحص قدرات تلقائي	حرية كاملة للمستخدم أو المنشأة في ربط أي موديل سحابي أو محلي بأقل تكلفة
سجل الأدوات (Typed Tool Registry)	أدوات قراءة وكتابة بصلاحيات خادمية	إضافة فصل مخرجات الأدوات (LLM Output vs UI Details) مع التحميل التدريجي للمهارات	سرعة استجابة مضاعفة وتوفير 70% من استهلاك التوكنز مع رسم فوري للبطاقات
الذاكرة (Memory Layers)	فصل مفاهيمي بين سياق المحادثة وملف المنشأة	بناء محرك ذاكرة خماسي الطبقات مع ملفات `BUSINESS_DNA.md` وأدوات تعديل ذاكرة ذاتية	تحول الوكيل إلى موظف يحفظ طباع صاحب الشغل وأسماء الأصناف الدارجة دون تلقين متكرر
وقت تشغيل الوكيل (Agent Runtime)	حلقة تنفيذ خطية (Receive → Parse → Execute)	ترقيتها إلى حلقة تخطيط وتفكيك مهام (Task DAG) مع دعم المقاطعة والطوابير (AbortController)	قدرة الوكيل على تنفيذ أوامر مركبة من 10 خطوات في رسالة واحدة مع إمكانية التعديل اللحظي
طبقة الواجهة (Web / Mobile UI)	محادثة بجانبها بطاقات تأكيد وسجل نشاط	ربطها ببروتوكول أحداث الواجهة (AG-UI) ليصبح الموديل قادراً على فتح الشاشات وتخصيصها	تجربة مستخدم سحرية يقودها الموديل بالكامل وتتكيف مع نوع النشاط تلقائياً

يتيح هذا المسار التراكمي الحفاظ على كافة استثمارات الكود السابقة، إذ يتحول كل استدعاء في طبقة الخدمات الحالية (`Domain Application Modules`) إلى أداة قياسية مسجلة في الهارنيس. وعندما يطلب الموديل تنفيذ عملية بيع أو تجديد اشتراك أو جرد مخزن، فإنه لا يكتب استعلام SQL مباشر، بل يستدعي الأداة المحددة التي تمر حتماً عبر محرك السياسات ومفاتيح منع التكرار والـ Transactional Outbox الموجودة بالفعل في نواة «وكيل».

3. تشريح معمارية الهارنيس القياسية: دروس من أنظمة Pi وOpenCode وDeepSeek وClaude

لفهم كيف يمكن لهارنيس «وكيل» أن يجعل أي نموذج ذكاء اصطناعي يعمل بكفاءة موظف خبير، ينبغي تشريح أحدث المعماريات الهندسية التي أثبتت تفوقها في بيئات الإنتاج خلال عامي 2025 و2026، وعلى رأسها معمارية Pi Coding Agent التي ابتكرها المهندس Mario Zechner، ومقارنتها بمعمارية OpenCode، وبنية نظام أوامر Claude البالغ 16,739 كلمة، وهندسة استدعاء الأدوات والتخزين المؤقت في DeepSeek API.

فلسفة البساطة الموجهة وهندسة السياق في معمارية Pi

كشفت التجارب العملية التي وثقها Mario Zechner عند بناء معمارية Pi (pi-ai وpi-agent-core وpi-coding-agent) عن حقيقة هندسية بالغة الأهمية: إن تضخم برومبت النظام (System Prompt) وتكديس عشرات الأدوات في كل طلب يدمر دقة النموذج، ويستهلك نافذة السياق، ويرفع زمن الاستجابة والتكلفة. فبينما يبلغ طول برومبت النظام في Claude نحو 16,739 كلمة (قرابة 110 كيلوبايت) تشكل تعريفات الأدوات وتعليماتها نحو 80% منه وفق تحليل Drew Breunig المعماري لبرومبت Claude، وتستهلك خوادم MCP الشائعة ما بين 13,700 إلى 18,000 توكن قبل أن يكتب المستخدم كلمة واحدة، اعتمدت معمارية Pi على برومبت نظام لا يتجاوز 150 إلى 1,000 توكن وأربع أدوات أساسية فقط. ورغم هذا الاختزال الجذري، تصدرت معمارية Pi اختبارات Terminal-Bench 2.0 وتفوقت في الاستخدام اليومي على أنظمة أكثر تعقيداً مثل OpenCode وCursor.

يرجع سر هذا التفوق إلى أربعة ابتكارات معمارية في Pi يجب استنساخها وتكييفها مباشرة داخل هارنيس «وكيل» المحاسبي:

1. **الإفصاح التدريجي عن المهارات (Progressive Disclosure via Skills & Context Files)**: بدلاً من شحن كافة قواعد الصيدليات، والعطارة، والسوبر ماركت، والجيمات، وتعليمات الضرائب، وقواعد الجرد داخل الـ System Prompt في كل رسالة، يحتفظ الهارنيس ببرومبت أساسي رشيق جداً، ويحمل فقط ملف السياق الخاص بالمنشأة (`BUSINESS_DNA.md` المكافئ لملف `AGENTS.md` في Pi). أما المهارات المتخصصة (مثل «دليل تسوية جرد العطارة» أو «قواعد تجميد اشتراكات الجيم»)، فيتم تخزينها كملفات مهارات (`SKILL.md`) يقرؤها الوكيل عند الحاجة فقط عبر أداة قراءة سريعة، مما يبقي السياق نظيفاً وحاد التركيز.
2. **فصل مخرجات الأداة المزدوج (Structured Split Tool Results)**: في مكتبة `pi-ai`، عندما تنفذ الأداة عملية ما، فإنها لا تعيد نصاً واحداً فقط، بل تعيد كائناً مزدوجاً يحتوي على حقل `output` (ملخص نصي مضغوط جداً موجه للنموذج اللغوي ليكمل تفكيره بأقل عدد من التوكنز) وحقل `details` (كائن بيانات مهيكل غني بالتفاصيل موجه مباشرة لواجهة المستخدم UI لرسم البطاقات والجداول والرسوم البيانية دون الحاجة إلى أن يعيد النموذج كتابتها أو تحليلها). في «وكيل»، عندما يستدعي الموديل أداة `get_supplier_statement`، يذهب الجدول المالي الكامل فوراً إلى الواجهة عبر حقل `details`، بينما يستلم الموديل في حقل `output` سطرين فقط: `{"supplier":"محمد العطار", "net_balance_piasters": 150000}` و`{"overdue_invoices": 2}`، مما يختصر زمن توليد الرد بنسبة تتجاوز 60%.
3. **التحليل الجزئي لتدفق JSON أثناء استدعاء الأداة (Partial JSON Streaming)**: يقوم `pi-ai` بتحليل معاملات استدعاء الأداة (Tool Call Arguments) تدريجياً أثناء تدفقها من النموذج (SSE Stream) قبل اكتمال الإغلاق النهائي لكائن JSON، مع التحقق النهائي الصارم عبر مخططات TypeBox ومكتبة AJV. هذا يسمح لواجهة «وكيل» بإظهار بطاقة الفاتورة أو سند القبض وهي تتشكل أمام عين التاجر لحظة بلحظة في أجزاء من الثانية.
4. **الحالة الخارجية المرئية للمهام والخطط (`TODO.md` / `PLAN.md`) بدلاً من الصناديق السوداء**: يرفض تصميم Pi إخفاء خطط الوكيل داخل وكلاء فرعيين غامضين (Black-box Sub-agents) لا يراهم المستخدم، ويستبدل ذلك بكتابة حالة الخطة وقائمة المهام في بنية خارجية صريحة ومرئية يقرؤها الوكيل ويحدثها خطوة بخطوة ويمكن للمستخدم تعديلها أو إيقافها في أي لحظة.

هندسة استدعاء الأدوات الصارم والتخزين المؤقت في DeepSeek

على الجانب الآخر، توضح وثائق DeepSeek API لاستدعاء الأدوات (Tool Calls) والتحديثات الخاصة بـ DeepSeek V3.2 وV4 Flash كيف تتعامل النماذج الحديثة مع التفكير المتداخل مع الأدوات (Thinking Mode Tool Use). فمنذ إصدار DeepSeek-V3.2، بات النموذج يدعم استدعاء الأدوات أثناء طور التفكير العميق، كما يوفر وضع الالتزام الصارم بالمخطط (`strict: true`) عبر نقطة النهاية التجريبية أو المتوافقة) الذي يجبر الموديل على إخراج JSON يطابق تعريف الأداة بنسبة 100% بشرط تحديد كافة الخصائص ضمن مصفوفة `required` وضبط `additionalProperties: false`.

الأهم من ذلك لتطبيق «وكيل» هو آلية التخزين المؤقت التلقائي للسياق (Context Caching) في DeepSeek؛ حيث يتم مطابقة بادئة البرومبت (Prompt Prefix) تلقائياً على مستوى البايت والتوكن مع ذاكرة الكاش السريعة دون الحاجة إلى علامات تحكم يدوية، مما يخفض تكلفة قراءة المليون توكن من 0.29 دولار إلى 0.06 دولار فقط (وفر يقارب 80% أي أرخص بنحو 4.8 مرة)، فضلاً عن تقليص زمن انتظار أول توكن (TTFT) بشكل جذري في حلقات الوكيل المتعددة الجولات. غير أن هذا الكاش ينكسر فوراً إذا تسرب أي عنصر متغير (مثل الوقت الحالي `timestamp` أو معرف الجلسة العشوائي أو إعادة ترتيب مفاتيح JSON) إلى بداية البرومبت؛ وهي قاعدة ذهبية ستشكل حجر الزاوية في تصميم البرومبت الموحد لـ «وكيل».

الخاصية المعمارية	معمارية Claude / Claude Code	معمارية OpenCode	معمارية Pi (`pi-ai` / `pi-coding-agent`)	التصميم الهجين المستهدف لهارنيس «وكيل»
حجم برومبت النظام	ضخم جداً (~16,739 كلمة في العام)	متوسط إلى كبير (مشتق من قوالب مخصصة لكل موديل)	فائق الصغر (<1,000 توكن شامل الأدوات الأربع)	نواة ثابتة رشيقة (~800 توكن) + حقن مهارات عند الطلب
تعدد المزودين (BYOK)	مقيد غالباً بـ Anthropic أو عبر وسطاء	يدعم عدة مزودين عبر Vercel AI SDK مع مشاكل توافق محلي	محول أصلي رباعي البروتوكولات يدعم أي Base URL وOllama	محول أصلي رباعي البروتوكولات + فاحص قدرات + محاكاة أدوات
إدارة المهام الفرعية	وكلاء فرعيون مخفيون (Sub-agents) يصعب تتبعهم	وضع تخطيط داخلي (Plan Mode)	حالة خارجية مرئية (`PLAN.md` / `TODO.md`) قابلة للتعديل	شجرة مهام مرئية في الواجهة (Interactive Task Checklist)
مخرجات الأدوات	نص/JSON موحد يمر عبر الموديل بالكامل	نص موحد يعاد تحليله في الواجهة	فصل مزدوج (`output` للموديل + `details` للواجهة)	فصل مزدوج: ملخص بالقرش للموديل + حمولة غنية لبطاقات الواجهة
نموذج الصلاحيات	نوافذ استئذان متكررة تسبب إرهاق الموافقة	صلاحيات أوامر برمجية	تشغيل مفتوح للمبرمجين (YOLO) أو قراءة فقط	مصفوفة مخاطر محاسبية (R0-R4) مع تنفيذ فوري للمنخفض واعتماد للعالي

4. بوابة النماذج الشاملة (Universal BYOK Router) والتوافق مع كافة المزودين

يطلب تصميم «وكيل» تمكين أي صاحب عمل أو مطور أو شريك نشر من إدخال عنوان الربط (`Base URL`) ومفتاح الواجهة (`API Key`) واسم النموذج (`Model ID`) لأي مزود ذكاء اصطناعي في العالم — سواء كان DeepSeek، أو OpenAI، أو Anthropic، أو Google Gemini، أو OpenRouter، أو Groq، أو Cerebras، أو حتى خادماً محلياً يعمل داخل الصيدلية أو السوبر ماركت عبر Ollama أو vLLM أو LM Studio — ليعمل الهارنيس بكامل قدراته المحاسبية والتشغيلية دون أي تعديل في الكود.

قاعدة البروتوكولات الأربعة وتطبيع الفروقات البرمجية

كما أثبتت التجربة العملية في بناء مكتبة `pi-ai`، فإن التخاطب مع كافة مزودي النماذج اللغوية في العالم لا يتطلب سوى دعم أربعة بروتوكولات أساسية فقط: 1. **OpenAI Chat Completions API (`/v1/chat/completions`)**: وهو البروتوكول الأكثر انتشاراً الذي تتحدثه DeepSeek، وGroq، وCerebras، وOpenRouter، وMistral، وxAI، ومحركات التشغيل المحلية مثل Ollama وvLLM و**OpenAI Responses API (`/v1/responses`)**: البروتوكول الأحدث من OpenAI والمدعوم جزئياً في llama.cpp. 2. DeepSeek Responses API لإدارة السياق واستدعاء الأدوات وإدراج الرسائل وسط المحادثة. 3. **Anthropic Messages API (`/v1/messages`)**: البروتوكول الأصلي لنماذج Claude، والذي باتت تدعمه أيضاً منصات مثل DeepSeek عبر نقطة توافق Anthropic لتسهيل ربط أدوات الوكلاء. 4. **Google Generative AI API**: البروتوكول الأصلي لنماذج Gemini.

غير أن الخدعة الكبرى التي تفشل فيها المكتبات الجاهزة (مثل Vercel AI SDK عند التعامل مع النماذج المستضافة ذاتياً أو المزودين البديلين) هي أن كل مزود يطبق بروتوكول `OpenAI Completions` بتفسيرات خاصة واختلافات دقيقة. فبعض المزودين (مثل Cerebras وxAI وMistral) يرفضون حقل `store` أو لا يدعمون دور `developer` لرسائل النظام، وبعضهم يشترط `max_tokens` بدلاً من `max_completion_tokens`، كما تختلف النماذج في اسم الحقل الذي يعيد مسار التفكير الداخلي بين `reasoning_content` (في DeepSeek) و`reasoning` (في مزودين آخرين)، فضلاً عن أن تحليل استجابة DeepSeek بخلطها مع OpenAI Responses قد يؤدي إلى إسقاط مسار التفكير بالكامل إن لم ينتبه المحول البرمجي لذلك.

لذلك، يجب أن يضم هارنيس «وكيل» طبقة **محول تطبيع المزودين (Provider Normalization Adapter)** التي تقوم بالمهام التالية تلقائياً عند إدخال المستخدم لمفتاحه ورابطه:

التحدي التقني بين المزودين	سبب المشكلة في أنظمة BYOK التقليدية	الحل الهندسي داخل بوابة نماذج «وكيل» (Wakil Universal Router)
اختلاف دعم strict JSON Schema	بعض المزودين المحليين لا يدعمون `strict: true` أو `anyOf` ويرجعون خطأ 400	فحص تلقائي؛ إن لم يدعم المزود الوضع الصارم، يتم التحقق عبر TypeBox/AJV في الخادم مع إعادة تغذية خطأ التحقق للموديل لتصحيحه ذاتياً
عدم دعم الموديل لـ Tool Calling أصلياً	بعض النماذج المفتوحة أو الصغيرة تفشل في إخراج `tool_calls` قياسية	تفعيل وضع محاكاة الأدوات (Tool Emulation كما في Inspect AI) بحقن قالب JSON/XML للأدوات في البرومبت وتحليله خادمياً
إدراج نتائج أدوات وسط المحادثة	واجهة Chat Completions لا تقبل `tool_calls` دائماً إدراج لم يولدها الموديل	تحويل العمليات المحقونة من الواجهة (مثل ضغطة زر يدوية من الكاشير) إلى رسائل `user` أو `system` مهيكلة عند استخدام Chat Completions
التبديل بين الموديلات أثناء الجلسة	التوقيعات المشفرة وحقول التفكير الخاصة بـ Anthropic أو OpenAI تكسر المزود الآخر	تطبيق خوارزمية نقل السياق (Context Handoff) بتحويل كتل التفكير إلى وسوم `<thinking>` نصية وتجريد التوقيعات الخاصة قبل الإرسال للمزود الجديد
إلغاء الطلبات العالقة (Aborts)	المستخدم يضغط إيقاف أو يعدل كلامه بينما الموديل يستدعي أداة	تمرير `AbortController` عبر كامل خط الأنابيب لقطع التدفق فوراً والاحتفاظ بالمحتوى الجزئي دون تنفيذ الأداة الملغاة

بروتوكول الفحص التلقائي عند ربط موديل جديد (Provider Capability Probe)

عندما يفتح صاحب العمل أو مسؤول النظام شاشة إعدادات الذكاء الاصطناعي في «وكيل» ويضع `Base URL` و`API Key`، لا يكتفي النظام بحفظ النص، بل يشغل في الخلفية خلال ثانيتين «فاحص قدرات مصغر» (Micro-Probe) يرسل 3 طلبات اختبارية صغيرة جداً (تستهلك أقل من 150 توكن) ليكتشف تلقائياً: 1. هل يدعم المزود التدفق اللحظي (`stream: true`) وإرجاع استهلاك التوكنز والكاش (`prompt_cache_hit_tokens`)؟ 2. هل يدعم المزود استدعاء الأدوات الأصلي (`tools`) وهل يقبل مخططات JSON الصارمة (`strict: true`)؟ 3. ما هو متوسط زمن أول توكن (TTFT) وسرعة توليد التوكنز في الثانية (TPS) لهذا الرابط؟

بناءً على نتيجة هذا الفحص، ينشئ «وكيل» ملف تعريف قدرات للمزود (`ProviderCapabilityProfile`) ويضبط سلوكه تلقائياً. فإذا ربط المستخدم مثلاً حساب DeepSeek V3.2 أو V4 Flash، يفعل النظام تلقائياً استراتيجية الكاش الصارم وأدوات JSON المهيكلة. وإذا ربط المستخدم نموذجاً محلياً صغيراً عبر Ollama على جهاز الكاشير للعمل بدون إنترنت، يفعل النظام تلقائياً وضع البرومبت المختصر جداً (Ultra-Compact Prompt) ومحاكاة الأدوات الحتمية.

5. هندسة السرعة الفائقة وزمن الاستجابة اللحظي (Sub-Second Latency Architecture)

في بيئة الصيدلية المزدحمة أو كاشير السوبر ماركت أو محل العطارة، تُعد السرعة مسألة حياة أو موت للمنتج؛ فالتاجر لن ينتظر 8 ثوانٍ أمام الزبون ريثما يفكر النموذج اللغوي ويستدعي ثلاث أدوات على التوالي ثم يصيغ فقرة إنشائية. لكي يكون «وكيل» أسرع موظف في العالم، يجب تصميم الهارنيس بحيث يشعر المستخدم بأن الاستجابة فورية (أقل من 300 إلى 800 مللي ثانية لظهور النتيجة الأولية)، حتى عندما يكون النموذج الخلفي بعيداً عبر الإنترنت.

تحقيق هذه السرعة الفائقة لا يعتمد على سرعة الموديل وحده، بل على **معمارية التسريع خماسية المراحل** داخل الهارنيس نفسه:

المرحلة الأولى: المسار الحتمي السريع والتوجيه الدلالي الهجين (Tiered Fast-Path & Agentic Routing)

تُظهر الأبحاث الحديثة حول التوجيه الوكيلي ودولاب البيانات المدمج في الهارنيس (Agentic Routing) أن معاملة كافة طلبات المستخدم بنفس مستوى التعقيد هي إهدار هائل للوقت والمال. في «وكيل»، تمر كل رسالة عبر مصنف فائق السرعة داخل الخادم (يستغرق أقل من 15 إلى 50 مللي ثانية): - **المستوى صفر (<20ms) — Deterministic Regex / Command Parser**: الأوامر القياسية المتكررة جداً أو المختصرة (مثل مسح باركود، أو كتابة «رصيد الدرج»، أو «حضور 01012345678»، أو الضغط على زر اختصار في الواجهة) تُنفذ مباشرة عبر دوال المجال الحتمية وتُحدث سجل المحادثة دون انتظار رحلة ذهاب وعودة كاملة للنموذج اللغوي. - **المستوى الأول (250ms–600ms) — Flash / Small Model Fast-Turn**: العمليات اليومية الواضحة من خطوة واحدة (مثل: «بيعت علبتين بنادول إكسترا كاش»، أو «سجل 50 جنيه فاتورة كهرباء من الدرج»، أو «بـ 20 جنيه فلفل أسود») توجه إلى نموذج فائق السرعة ومنخفض التكلفة (مثل `deepseek-flash` أو `gemini-2.5-flash` أو `llama-3.3-70b` على

(Groq/Cerebras مع تعطيل التفكير الطويل (`thinking: false`) لإنتاج استدعاء الأداة في أقل من نصف ثانية. - **المستوى الثاني (Deep Reasoning & Multi-Step Planner — 1.5s–4s)**: الأوامر المركبة أو التحليلية أو الغامضة (مثل: «راجعلي فواتير الموردين بتوع الشهر ده وشوف مين اللي زود علينا سعر الشيكارة عن الشهر اللي فات واعمل بيهم جدول»، أو «جرد معايا الرف ده وصفي الفروقات») توجه إلى نموذج التفكير العميق (مثل `deepseek-reasoner` / R1 أو Claude Sonnet أو GPT-5) مع فتح قائمة مهام تفاعلية.

المرحلة الثانية: الجلب الاستباقي المتوازي للكيانات (Speculative Entity Prefetching)

في الأنظمة التقليدية، يقرأ الموديل جملة «اديت محمد العطار 1000 جنيه من حسابه»، فيستدعي أولاً أداة `search_supplier("محمد العطار")`، وينتظر النتيجة (رحلة LLM أولى = 1.2 ثانية)، ثم يقرأ الـ ID ويستدعي أداة `record_payment(supplier_id=42, amount=1000)` (رحلة LLM ثانية = 1.2 ثانية)، ثم يكتب الرد النهائي (رحلة LLM ثالثة = 1.0 ثانية)؛ أي ما مجموعه 3.4 ثانية!

يقضي هارنيس «وكيل» على هذه الرحلات المتعددة عبر **المحلل الاستباقي (Speculative Pre-Resolver)**: بمجرد وصول نص المستخدم إلى الخادم (بل وأثناء كتابته في خانة الإدخال عبر البحث الضبابي السريع في الذاكرة المحلية IndexedDB/SQLite)، يلتقط الهارنيس الكلمات المفتاحية والأسماء والأرقام في أقل من 15 مللي ثانية، ويجلب من قاعدة البيانات أقرب المطابقات للأصناف والموردين والأعضاء والعملاء، ويحقنها مباشرة في ذيل الرسالة المرسلة للموديل في الجولة الأولى: `[System Prefetched] Entities: Supplier "محمد العطار" (id: sup_42, current_balance: 2500.00 EGP)`. بهذه الحيلة المعمارية، يمتلك الموديل الـ `id` والرصيد الحالي منذ اللحظة الأولى، فيصدر أمر التنفيذ أو بطاقة المعاينة في **جولة واحدة فقط (Single-Turn Execution)** بدلاً من ثلاث جولات!

المرحلة الثالثة: هندسة بادئة الكاش المطابقة للبايت (Byte-Identical Prefix Caching)

استناداً إلى الأرقام الموثقة في هندسة التخزين المؤقت لـ DeepSeek V3.2 وتوثيق OpenAI Prompt Caching، يضمن هارنيس «وكيل» بقاء نسبة إصابة الكاش (Cache Hit Ratio) فوق 85% عبر القواعد الصارمة التالية: 1. **تجميد البادئة (Frozen Prefix)**: يتكون أول جزء من السياق من برومبت النظام الأساسي + مخططات الأدوات المرتبة أبجدياً بشكل حتمي (Deterministic Sorting) + دستور المنشأة (`BUSINESS_DNA.md`). لا يُسمح أبداً بوضع الوقت الحالي (`current_time`) أو رصيد الخزنة المتغير أو اسم الكاشير المتغير في أعلى برومبت النظام. 2. **ترحيل المتغيرات إلى الذيل (Dynamic Tail Injection)**: تُحقن كافة البيانات المتغيرة (الوقت المحلي، الكيانات المستخرجة استباقياً، حالة الشاشة الحالية، ورسالة المستخدم) في نهاية السياق تماماً. 3. **إبقاء السياق دافئاً (Cache Warm-up)**: عند فتح الوردية صباحاً في المحل أو الصيدلية، يرسل الخادم طلباً صامتاً خفيفاً لتسخين بادئة الكاش الخاصة بالمنشأة بحيث تكون أول معاملة يجريها التاجر سريعة كالبرق.

مرحلة المعالجة داخل هارنيس «وكيل»	الزمن المستهدف في الأنظمة التقليدية	الزمن المستهدف في هارنيس «وكيل»	التقنية الهندسية المعتمدة لتحقيق الاختصار
تحليل النية والبحث عن الأسماء والأصناف	800 – 1,500 مللي ثانية (جولة أداة منفصلة)	10 – 25 مللي ثانية	البحث الاستباقي المتوازي (Speculative Entity Prefetching) قبل استدعاء الموديل
معالجة بادئة النظام والأدوات (Prompt Prefill)	600 – 1,200 مللي ثانية	80 – 180 مللي ثانية	تطابق البايت في البادئة (Byte-Identical Prefix Caching) وترتيب JSON الحتمي
توليد استدعاء الأداة (Tool Call Generation)	1,000 – 2,500 مللي ثانية	200 – 450 مللي ثانية	التوجيه لنماذج Flash في المهام المباشرة + التحليل الجزئي لـ JSON أثناء التدفق
تنفيذ القيد وعرض البطاقة في الواجهة	1,200 – 2,000 مللي ثانية (انتظار صياغة الموديل)	30 – 80 مللي ثانية	فصل المخرجات (`details`) يذهب للواجهة فوراً بينما يولد الموديل سطر التأكيد)
إجمالي الزمن المدرك للمستخدم (Perceived Latency)	**3.6 – 7.2 ثانية**	**0.32 – 0.73 ثانية**	**دمج المسارات الخمسة مع تحديث الواجهة المتفائل (Optimistic Streaming UI)**

6. منظومة الذاكرة الحية خماسية الطبقات والتعلم الذاتي المستمر

يريد صاحب العمل موظفاً حقيقياً: إذا قال له اليوم «يا وكيل، الحاج عبد الفتاح لما يبعت ابنه ياخد سجاير أو طلبات، اكتبها على حساب الحاج عبد الفتاح بس متزودش عن 500 جنيه في الأسبوع»، أو قال له في الصيدلية «لما أقولك أوجمنتين شراب الصغير قصدي تركيز 457»، فإن «وكيل» لا ينبغي أن ينسى هذه المعلومة أبداً، ولا ينبغي أن يحتاج إلى مبرمج لتعديل الكود، بل يجب أن يتذكرها، ويطبقها، ويعدلها إذا تغيرت الظروف، ويتحسن أداؤه كلما اشتغل أكثر في المحل.

المقارنة المعمارية بين ذاكرة ChatGPT وذاكرة Claude وذاكرة Pi

كشفت دراسات الهندسة العكسية التي أجراها Shlok Khemani على منظومة ذاكرة ChatGPT والمقارنة المعمارية التي وثقها Simon Willison بين ذاكرة Claude وChatGPT عن مدرستين مختلفتين تماماً في بناء ذاكرة الذكاء الاصطناعي:

- **مدرسة الحقن الشامل المسبق (ChatGPT Always-On Preloaded Memory)**: لا يستخدم ChatGPT قواعد بيانات المتجهات (Vector RAG) في ذاكرته الشخصية، بل يحقن في بداية كل محادثة أربع حاويات معلوماتية دفعة واحدة:
- `Interaction Metadata`: بيانات سلوك المستخدم والجهاز وأنماط الاستخدام.
- `Recent Conversation Content`: عناوين ومقتطفات رسائل المستخدم (دون ردود المساعد لتجنب تلويث السياق بالهلوسات السابقة) من آخر 40 محادثة.
- `Model Set Context`: جمل صريحة ومؤرخة أضافها الموديل بناءً على طلب المستخدم أو تصحيحه، وهي طبقة الحقيقة العليا (Patch Layer) التي يراها المستخدم ويتحكم فيها وتنسخ أي معلومة قديمة متناقضة.
- `User Knowledge Memories`: ملخصات كثيفة مكونة من نحو 10 فقرات يولدها الذكاء الاصطناعي دورياً في الخلفية لتلخيص عادات المستخدم ومشاريعه وتفضيلاته.
- **مدرسة الاستدعاء عند الطلب والملفات الصريحة (Claude On-Demand Tool Memory & Pi Context Files)**: يبدأ Claude المحادثة بصفحة بيضاء لتجنب إرباك السياق، ويمنح الموديل أداتي بحث صريحتين هما `conversation_search` و`recent_chats` لاسترجاع التفاصيل التاريخية متى احتاج إليها، إلى جانب ملخص ذاكرة المشروع القابل للتحرير في حسابات الفرق (`Project Memory Summary`). أما Pi Coding Agent فيعتمد على ملفات نصية مهيكلة هرمياً (`AGENTS.md` و`SKILL.md`) يقرؤها الوكيل ويحدثها مباشرة على القرص.

بالنسبة لمنظومة محاسبية وتشغيلية مثل «وكيل»، فإن الاعتماد على مدرسة ChatGPT وحدها خطر لأن الملخصات الآلية الخفية (`User Knowledge Memories`) قد تحتفظ بمعلومات قديمة غير صحيحة (مثل اعتقاد الموديل أن سعر صنف أو سياسة خصم قديمة لا تزال سارية)، بينما الاعتماد على مدرسة Claude وحدها يجعل الموديل ينسى البديهيات اليومية للمحل ما لم يبحث عنها في كل مرة. لذلك، يصمم هارنيس «وكيل» **منظومة الذاكرة الهجينة خماسية الطبقات (Wakil 5-Layer Hybrid Memory Architecture)** التي تجمع مزايا المدرستين مع صرامة الأنظمة المالية:

طبقة الذاكرة في «وكيل»	المكافئ المعماري المرجعي	ماذا تخزن تحديداً في بيئة العمل؟	كيف ومتى تُقرأ وتُحدث؟
1. دستور المنشأة الصريح (BUSINESS_DNA)	`Model Set Context` في ChatGPT + `AGENTS.md` في Pi	قوانين المحل، حدود الآجل، نسب عمولات المدربين، مواعيد الورديات، سياسة المرتجعات، تفضيلات صاحب العمل	تُحقن دائماً في البادئة الثابتة؛ وتُحدث فوراً عبر أداة `memory_upsert_rule` مع إشعار واضح للمالك
2. القاموس الدلالي المتعلم (LEXICON_GRAPH)	جدول مرادفات سريع + FTS5/Trigram Index	الأسماء الشعبية والدارجة للأصناف، ألقاب العملاء («أبو كريم البواب»)، اختصارات الأدوية، تحويلات الوحدات الخاصة بالمحل	تُقرأ استباقياً في 10ms قبل استدعاء الموديل؛ وتُحدث تلقائياً عبر أداة `lexicon_learn_alias` كلما وضح المستخدم اسماً جديداً

طبقة الذاكرة في «وكيل»	المكافئ المعماري المرجعي	ماذا تخزن تحديداً في بيئة العمل؟	كيف ومتى تُقرأ وتُحدث؟
3. ذاكرة المهارات المتطورة (SKILLS_PLAYBOOKS)	نظام `SKILL.md` في Pi Coding Agent	خطوات العمل المتكررة الخاصة بالمحل (مثل طريقة تقفيل حساب يوم الخميس، أو معادلة خلطة البهارات السرية، أو روتين جرد الثلاجة)	يُقرأ فهرس عناوينها دائماً، ويُسحب نص المهارة الكامل عبر `skill_read` عند الحاجة؛ ويقترح الموديل مهارات جديدة عبر `skill_propose`
4. سجل الذاكرة الحادثية (EPISODIC_LOG)	أدوات `conversation_search` و`recent_chats` في Claude	المحادثات السابقة، أسباب رفض عمليات معينة، الملاحظات الصوتية، اتفاقات الموردين الشفهية المسجلة	لا تُحقن بالكامل؛ يستدعيها الموديل عند الطلب عبر أداة `memory_search_episodes` مفلترة بالتاريخ أو الكيان
5. ضاغط الجلسة النشطة (SESSION_COMPACTOR)	`Compaction` في Pi + `Recent Context` في ChatGPT	رسائل الوردية الحالية مع ضغط المحادثات الطويلة دون فقدان أي رقم معاملة أو معرف كيان	يعمل تلقائياً عند وصول السياق إلى 70% من الحد الأقصى، مع حفظ كافة المعرفات (`tx_id`, `sku_id`) في كتلة حالة محمية

كيف يعدل الموديل ذاكرته بنفسه ويتطور مع الشغل كموظف حقيقي؟

لكي لا تكون الذاكرة مجرد أرشيف ميت، يزود هارنيس «وكيل» النموذج اللغوي بأربع أدوات ذاكرة أصلية (Native Memory Tools) يستدعيها الموديل تلقائياً أثناء الحوار متى اكتشف معلومة دائمة جديدة:

1. **`memory_upsert_rule(category, rule_key, rule_statement, requires_owner_confirm)`**: عندما يقول صاحب الجيم: «بص يا وكيل، أي اشتراك سنوي ليه تجميد شهرين بحد أقصى مرتين في السنة، لو زاد عن كده ياخد موافقتي الأول»، يستدعي الموديل هذه الأداة فوراً لتسجيل القاعدة في `BUSINESS_DNA` تحت تصنيف `membership_policies`. وفي حال عدل صاحب العمل كلامه بعد شهر قائلاً: «خلي التجميد 45 يوم بس»، يستدعي الموديل نفس الأداة بنفس الـ `rule_key` فيقوم بتحديث القاعدة (Patch/Override) وحفظ القاعدة القديمة في سجل تاريخ الذاكرة (`memory_audit_log`) مع التاريخ واسم المعدل، تماماً كما تفعل طبقة `Model Set Context` في منع التضارب مع الذكريات القديمة.
2. **`lexicon_learn_alias(spoken_phrase, canonical_entity_type, canonical_entity_id, confidence)`**: لنفترض أن الكاشير قال: «اديني كيسين شيبسي عائلي»، فبحث «وكيل» ووجد صنفين: «شيبسي طماطم جامبو 90 جم» و«شيبسي عائلي 150 جم»، فسأل الكاشير: «تقصد العائلي 150 جم بـ 25 جنيه؟»، فرد الكاشير: «أيوه هو ده دايماً لما أقولك عائلي». في نفس اللحظة، يستدعي الموديل أداة `lexicon_learn_alias` جنبًا إلى جنب مع أداة البيع! ومنذ تلك اللحظة، لن يسأل «وكيل» هذا السؤال مرة أخرى أبداً، لأن المحلل الاستباقي سيربط كلمة «شيبسي عائلي» بالـ SKU رقم `item_882` في 5 مللي ثانية.
3. **`skill_propose_or_update(skill_slug, trigger_description, steps_markdown, ui_shortcut_config)`**: هذه هي الآلية التي تجعل «وكيل» **يطور نفسه ويطور التطبيق نفسه باستمرار**. يراقب عامل خلفي (أو الموديل نفسه في نهاية الوردية) الأنماط المتكررة في سجل العمليات (`Transaction Journal`). فإذا لاحظ أن صاحب السوبر ماركت يقوم كل يوم سبت صباحاً بأربع خطوات متتالية: (1) مراجعة كشف حساب مورد الألبان، (2) خصم قيمة المرتجع التالف، (3) سداد الدفعة النقدية من الخزنة، (4) طباعة إيصال التسوية؛ يقوم «وكيل» بكتابة مهارة تشغيلية جديدة (`saturday-dairy-settlement`) ويعرض بطاقة ذكية لصاحب العمل: «*لاحظت إننا كل سبت بنعمل تسوية مورد الألبان في 4 خطوات.. تحب أثبتلك زرار سريع باسم (تسوية الألبان) يجهزلك الحسبة دي كلها بضغطة واحدة؟*». بمجرد موافقة المالك، يضيف الهارنيس هذا الاختصار تلقائياً إلى الشاشة الرئيسية!

4. **`memory_forget_or_rollback(memory_id, reason)`**: يتيح للمالك في أي وقت أن يقول «انسى القاعدة بتاعة خصم الـ 5%»، أو أن يفتح «شاشة ذاكرة وكيل» (Memory Inspector) ليرى كل ما تعلمه الموظف الذكي في شكل بطاقات واضحة مقسمة حسب الموضوع، ويحذف أو يعدل أي بند بضغطة زر.

7. تقسيم المهام المركبة وتحكم الموديل الكامل في واجهة التطبيق (Generative UI & AG-UI)

في واقع العمل اليومي، لا يتحدث التاجر العربي بجمل برمجية بسيطة تحتوي على أمر واحد، بل يلقي «دفعة أوامر مركبة» في رسالة صوتية أو نصية واحدة، مثل: *«يا وكيل، استلمت النهارده من مندوب شركة ابن سينا 20 علبة كونكور 5 مللي و15 علبة أوجمنتين 1 جرام، الفاتورة كلها بـ 4800 جنيه دفعت منها 2000 كاش والباقي آجل للشهر الجاي، وبالمناسبة كونكور زاد سعره للجمهور بقى بـ 135 جنيه، وشوفلي كده فاضل كام علبة أنسولين في التلاجة عشان لو ناقص نطلبه»*.

محرك تفكيك المهام المعتمد على الحالة المرئية (Stateful Task DAG Decomposition)

تتعثر الأنظمة البسيطة أمام هذا الأمر المركب لأنها تحاول تنفيذه في خطوة واحدة أو تضيع في منتصف الطريق إذا احتاجت إلى استفسار. أما هارنيس «وكيل» فيعتمد على **محرك تفكيك المهام التفاعلي (Interactive Task Planner)** المستلهم من دمج فلسفة `TODO.md` في Pi Coding Agent مع حلقات التنفيذ المهيكلة في معمارية Agent Harness الحديثة:

1. **التحليل والتقسيم الذري (Atomic Decomposition)**: عندما يكتشف الموديل أن الرسالة تحتوي على أكثر من نية تشغيلية (Multi-Intent Request)، فإنه يستدعي أداة `plan_create_task_list` في الجولة الأولى، والتي تنشئ فوراً على الشاشة قائمة مهام صغيرة (Micro-Task Checklist) مقسمة إلى خطوات مرتبة حسب الاعتمادية (Dependency Graph):
2. الخطوة 1: تحديث سعر بيع الجمهور لصنف «كونكور 5 مللي» إلى 135 جنيهاً (تُنفذ أولاً أو بالتوازي لأنها تؤثر على تقييم المخزون والتسعير).
3. الخطوة 2: تسجيل فاتورة مشتريات من مورد «ابن سينا» (20 كونكور + 15 أوجمنتين 1جم) بإجمالي 4800 جنيه.
4. الخطوة 3: تسجيل سند صرف نقدي من الخزنة بقيمة 2000 جنيه لصالح «ابن سينا» وترحيل 2800 جنيه كمديونية آجلة.
5. الخطوة 4: الاستعلام عن رصيد «الأنسولين» الحالي في مخزن الثلاجة ومقارنته بحد الطلب.
6. **التنفيذ المتتابع المعزول مع حفظ الحالة (Checkpointed Execution)**: ينفذ الهارنيس الخطوات ذات المخاطر المنخفضة والقراءة (`R0/R1`) فوراً، بينما يجهز الخطوات المالية (`R2/R3`) في بطاقة اعتماد مجمعة (Batch Approval Card) أو ينفذها حسب صلاحية المالك، مع وضع علامة صح خضراء أمام كل خطوة تكتمل.
7. **العزل الجزئي عند الغموض (Partial Execution without Blocking)**: إذا تبين في الخطوة الرابعة وجود 3 أنواع من الأنسولين في الصيدلية (Mixtard، Lantus، Actrapid)، فإن «وكيل» **لا يعطل** تسجيل فاتورة المشتريات وتحديث السعر في الخطوات 1 إلى 3! بل ينهي الخطوات الواضحة، ثم يترك الخطوة 4 في حالة `WAITING_CLARIFICATION` ويسأل الصيدلي: *«سجلت فاتورة ابن سينا والدفعة وتحديث سعر الكونكور تمام.. بالنسبة للأنسولين، عندك لانتوس (علبتين) ومكستارد (5 علب) وأكترابيد (صفر — خلصان)، تحب أضيف الأكترابيد في كشكول النواقص؟»*.

كيف يتحكم الموديل في كامل التطبيق؟ (Agent-Controlled Application Architecture)

لكي يتحقق هدف المشروع بأن «الموديل متحكم في كامل التطبيق ويطوره باستمرار ليلائم المستخدم»، يجب التخلي عن الفكرة القديمة التي تجعل الذكاء الاصطناعي محبوساً داخل مربع دردشة جانبي، وتبني معمارية **التطبيق المقود بالوكيل (Agent-Driven Application State)** استناداً إلى معايير بروتوكول AG-UI (Agent-User Interaction Protocol) وأنماط Generative UI الحديثة.

في هذه المعمارية، يمتلك المتصفح أو تطبيق الهاتف **مخزن حالة مركزي موحد (Unified Reactive Store)** (مثل Zustand أو Signals)، وتكون كل شاشة، وكل فلتر، وكل نافذة منبثقة، وكل جدول، وكل اختصار في التطبيق مربوطاً بهذا المخزن. ويزود الهارنيس النموذج اللغوي بمجموعة **أدوات التحكم في الواجهة والتطبيق (`UI & App Control Tools`)** التي تعمل جنباً إلى جنب مع أدوات قاعدة البيانات:

أداة التحكم في التطبيق	وظيفة الأداة داخل الهارنيس	مثال عملي لكيفية تحكم «وكيل» في التطبيق
`ui_navigate_and_filter`	فتح أي شاشة في التطبيق وتطبيق فلاتر وترتيب محدد تلقائياً	يقول المالك: «وريني الناس اللي عليها فلوس من الشهر اللي فات»، فيفتح الموديل شاشة المديونيات مفلترة بـ `overdue > 30d` ومرتبة تنازلياً بالمبلغ
`ui_render_generative_card`	رسم مكون تفاعلي مخصص داخل المحادثة أو اللوحة الجانبية	عند جرد العطارة، يرسم الموديل «بطاقة جرد تفاعلية» بها منزلقات أوزان وأزرار تسوية سريعة للأصناف الخمسة التي فيها عجز فقط
`ui_prefill_and_stage_form`	فتح نموذج معاملة معقد (مثل فاتورة 20 صنفاً) وملء كافة حقوله تلقائياً	يرفع التاجر صورة فاتورة مورد، فيفتح الموديل شاشة الفاتورة وقد ملأ الـ 20 صنفاً والأسعار والخصم، ويضع المؤشر باللون الأصفر على صنف واحد غير واضح في الصورة ليعدله التاجر
`ui_mutate_workspace_layout`	تعديل تصميم الشاشة الرئيسية للمنشأة وإضافة أزرار أو بطاقات مراقبة	يكتشف الموديل أن الجيم يركز جداً على حصص الـ PT في المساء، فيضيف ويدجت «جدول حصص الكباتن اليوم» وأزرار تسجيل حضور سريع في أعلى الشاشة الرئيسية
`ui_create_custom_tracker`	إنشاء جدول متابعة مخصص (Custom Micro-Module) لاحتياج جديد في المحل	يطلب صاحب سوبر ماركت: «عايز أتابع براميل المخلل اللي بتتفتح كل أسبوع»، فينشئ الموديل سجل متابعة مخصص بداخل التطبيق دون تدخل مبرمج

بهذه الآلية، يصبح التطبيق كله «عجينة طيعة» في يد الهارنيس: فإذا كان المستخدم يفضل الكلام فقط، يدير الموديل كل شيء ويعرض له بطاقات ملخصة داخل المحادثة؛ وإذا قال المستخدم «افتحلي كشف حساب محمد العطار وعدل الفاتورة التالتة»، يفتح الموديل الشاشة أمامه ويظلل الفاتورة الثالثة ويجهز التعديل!

8. تجربة المستخدم التفاعلية والتفاعلات الدقيقة وأنماط الاعتماد البشري (HITL)

تثبت التحليلات المعمقة لتجارب استخدام المنتجات الرائدة في دليل AI UX Playground لأنماط Human-in-the-Loop لعام 2026 وأنماط Chat Artifacts أن نجاح المساعد الذكي في بيئة الأعمال يتوقف على التوازن الدقيق بين **السرعة التلقائية** و**الثقة الرقابية**. فإذا طلب النظام موافقة يدوية على كل حركة صغيرة، سيتحول إلى واجهة بطيئة ومزعجة تدفع المستخدم إلى الضغط الأعمى على زر الموافقة (Confirm Spam)؛ وإذا نفذ كل شيء بصمت دون معاينة، سيفقد صاحب العمل الثقة عند أول خطأ في فهم رقم أو اسم.

هندسة التفاعلات الدقيقة (Micro-interactions) وطريقة عرض التفكير والرد

لكي يشعر المستخدم في مصر أو السعودية أو الخليج أن «وكيل» موظف بشري فائق الشطارة والسرعة، يجب تصميم التفاعلات الدقيقة (Micro-interactions) وفق القواعد السلوكية والبصرية التالية:

1. **كبسولة التفكير الحية بلغة الشغل (Live Domain Reasoning Pill)**: عندما يعمل الموديل أو يستدعي أداة، لا نعرض أبداً نصاً تقنياً جافاً مثل `Calling tool: get_supplier_balance_v2`، ولا نعرض صفحات طويلة من التفكير الداخلي المشتت. بدلاً من ذلك، يعرض الهارنيس كبسولة صغيرة أنيقة تتحرك بنعومة (160ms) وتترجم الخطوة الحالية إلى لغة التاجر:
2. 🔍 براجع رصيد الحاج سعيد في كشكول الآجل...
3. ⚖️ بحسب وزن الـ 15 جنيه كمون من شيكارة الـ 25 كيلو...
4. 💊 بتأكد من تاريخ صلاحية تشغيلة كونكور 5 مللي... هذا التفاعل الدقيق يبني ثقة فورية لأن صاحب العمل يرى «الموظف الذكي» وهو يتبع نفس الخطوات المنطقية التي يفعلها المحاسب الشاطر.
5. **التدفق التدريجي لبطاقة المعاملة (Progressive Card Hydration)**: أثناء نطق المستخدم للجملة أو فور إرسالها، تظهر بطاقة المعاملة على الشاشة في أقل من 200 مللي ثانية وتبدأ الحقول في الامتلاء تدريجياً بفضل الـ Partial JSON Streaming. الأرقام المالية تظهر بخط أحادي العرض (Tabular Numerals) يمنع اهتزاز الشاشة، مع تمييز لوني هادئ بين:
6. **حقل مؤكد من كلام المستخدم أو السجل** (نص كحلي/داكن ثابت).

7. **حقل استنتجه «وكيل» من الذاكرة أو السعر الافتراضي** (خلفية عنبرية فاتحة جداً مع أيقونة نجمة صغيرة ✦ سعر الكيلو المعتاد: `320` ج قابلة للضغط والتعديل الفوري).
8. **حقل ناقص يتطلب قراراً** (إطار متقطع واضح مع أزرار اختيار سريعة بلمسة واحدة دون كتابة).
9. **قاعدة الإيجاز الذكي في الردود (Zero-Fluff Conversational Receipts)**: الموظف المحاسبي المحترف لا يقول: «*أهلاً بك يا سيدي! بكل سرور قمت الآن بتسجيل عملية البيع الخاصة بك في قاعدة البيانات، وأتمنى لك يوماً مليئاً بالأرباح!*». هذا الأسلوب يقتل التجربة اليومية. في «وكيل»، الرد النصي بعد العملية الناجحة لا يتجاوز 6 إلى 12 كلمة طبيعية وحاسمة مرفقة ببطاقة الإيصال الموثق: «*سجلت بيع 250 جم كمون بـ 80 جنيه كاش، وخصمتهم من الشيكارة المفتوحة.*»

مصفوفة الاعتماد البشري والتنفيذ التلقائي المزود بالتراجع (HITL vs Optimistic Undo)

بالاستناد إلى مقارنة أنماط الموافقة في ChatGPT وGemini وPerplexity ودراسات حواجز استدعاء الأدوات في Scalekit، يطبق هارنيس «وكيل» ثلاث آليات تفاعل مختلفة بحسب مستوى خطورة الأداة (`R0` إلى `R4`) ودرجة ثقة الموديل في استخراج الحقول (`Confidence Score`):

مستوى المخاطرة ودرجة الثقة	نوع العملية في المحل أو الجيم أو الصيدلية	نمط تجربة المستخدم (UX Pattern) في «وكيل»	لماذا هذا النمط هو الأفضل؟
قراءة واستعلام (R0)	سؤال عن رصيد، سعر صنف، تاريخ انتهاء اشتراك، نواقص	**عرض فوري مباشر (Instant Inline Card)** بدون أي استئذان	القراءة لا تغير البيانات؛ السرعة القصوى هي المطلوبة
كتابة روتينية عالية الثقة (R1/R2 + ثقة >100%)	بيع نقدي عادي، تسجيل حضور عضو جيم، إضافة صنف لكشكول النواقص	**تنفيذ متفائل فوري مع شريط تراجع لمدة 10 ثوانٍ (Optimistic Commit + Undo Toast)**	يمنع تعطيل الكاشير في الزحام، مع إتاحة زر [تراجع ↩] واضح يلغي القيد فوراً إذا أخطأ الكاشير في النطق
كتابة بها حقل مستنتج أو غموض جزئي (R2 + ثقة <95%)	بيع آجل لعميل يتشابه اسمه، أو شراء بضاعة بسعر مختلف عن آخر فاتورة	**بطاقة مسودة تفاعلية بلمسة واحدة (Interactive Draft Card)** مع أزرار اختيار سريعة	يحمي السجل المالي من التسجيل على حساب عميل خاطئ دون إجبار المستخدم على إعادة كتابة الجملة
تعديل حساس أو عالي القيمة (R3)	تسوية عجز مخزون، عكس فاتورة، منح خصم استثنائي، تجميد اشتراك خارج اللائحة	**بطاقة اعتماد قبل/بعد (Diff Approval Gate)** تتطلب ضغطة اعتماد من صاحب الصلاحية	تطبيق لمبدأ «بطاقة الموافقة التي تخفي الحمولة هي مسرحية شكلية»؛ يعرض الرصيد قبل وبعد التعديل بوضوح
أثر خارجي لا رجعة فيه (R4)	إرسال رسائل واتساب جماعية للعملاء، تصدير قاعدة البيانات، حذف سجل	**بوابة تفويض مزدوجة مع ميزانية تنفيذ (Pre-Run Consent + Blast Radius Preview)**	يمنع الإرسال الخاطئ لآلاف العملاء أو تسريب البيانات بسبب حقن التعليمات

9. الدراسة الميدانية للقطاعات الأربعة في السوق العربي: الصيدليات، العطارة، السوبر ماركت، والجيمات

لكي يستغني صاحب العمل في مصر أو السعودية أو العالم العربي عن «الورقة والقلم» وعن البرامج التقليدية معاً، يجب أن يفهم هارنيس «وكيل» التفاصيل الدقيقة والخفية لكل نشاط من الأنشطة الأربعة المستهدفة — وهي التفاصيل التي تفشل فيها الأنظمة العامة لأنها لم تُصمم لواقع الشارع التجاري العربي.

أولاً: قطاع الصيدليات (Pharmacies) — إدارة التجزئة الدقيقة والصلاحيات والنواقص

تُظهر الدراسات الميدانية لمشكلات الصيدليات في مصر والسعودية كما توثقها أنظمة متخصصة مثل فارماكير لإدارة الصيدليات وميدكاكير لمخازن الأدوية أن الصيدلية العربية لا تبيع بالعبوة المغلقة فقط، بل تواجه خمس معضلات يومية يجب أن يحلها «وكيل» تلقائياً:

1. **تجزئة العبوة المتعددة المستويات (Multi-Level Sub-Unit Splitting)**: الدواء الواحد يُشترى بالكرتونة أو العلبة، لكنه يُباع بالعلبة (3 شرائط)، أو بالشريط (10 أقراص)، أو حتى بنصف شريط أو بالقرص/الأمبول الواحد! يجب أن يخزن نموذج بيانات

«وكيل» رصيد الدواء بأصغر وحدة قابلة للبيع (القرص أو الشريط) مع معامل تحويل صريح (`1 Box = 3 Strips = 30 Tablets`)، بحيث إذا قال الصيدلي «بعت شريطين كتافلام»، يخصم النظام شريطين ويعرض الرصيد المتبقي بصيغة بشرية مفهومة: 4 علب و1 شريط.

2. **تعدد التشغيلات وتواريخ الصلاحية والتسعير الجبري (Batch/Expiry FEFO & Dual Pricing)**: في مصر تحديداً، قد يوجد على نفس الرف علبتان من نفس الدواء بتشغيلتين مختلفتين (`Batch Number`)، إحداهما بالسعر القديم والأخرى بالسعر الجديد بعد تحريك أسعار الدواء، ولكل منهما تاريخ صلاحية مختلف (`Expiry Date`). يدير «وكيل» المخزون بقاعدة **الأقرب انتهاءً يخرج أولاً (FEFO)**، وعندما يقترب تاريخ صلاحية تشغيلة معينة (قبل 90 أو 60 يوماً)، ينبه الصيدلي استباقياً لتصريفها أو إرجاعها لشركة التوزيع (مثل ابن سينا، أو فارما أوفرسيز، أو المتحدة) قبل دخولها فترة الحظر.

3. **كشكول النواقص اللحظي والبدائل العلمية (Smart Shortages & Active Ingredient Substitutes)**: أكبر سبب لخسارة الصيدلية هو نسيان تدوين الصنف الذي سأل عنه المريض ولم يجده («الترجيعات»). في «وكيل»، بمجرد أن يقول الصيدلي: «حد سأل على نيكسيوم 40 ومعندناش»، يسجله «وكيل» فوراً في **كشكول النواقص الذكي**، ويعرض في نفس اللحظة البدائل المتوفرة على الرف التي تحتوي على نفس المادة الفعالة (`Esomeprazole 40mg`) وترتيبها حسب هامش ربح الصيدلي (خصم الصيدلي %)، وعندما يتصل مندوب المبيعات، يخرج «وكيل» طلبية النواقص جاهزة ومقارنة بأفضل خصم نقدي أو آجل بين المخازن.

ثانياً: قطاع العطارة والمحامص والحبوب (Spice, Herbal & Roastery Shops) — البيع بالقيمة المفتوحة والهالك والخلطات

تُبرز أنظمة إدارة محلات العطارة مثل برنامج ديكسيف لمحلات العطارة وبرنامج البدر لإدارة العطارة أن العطارة هي أصعب نشاط تجاري على أنظمة الكاشير التقليدية، وذلك للأسباب التالية التي يجب أن يتقنها «وكيل»:

1. **البيع العكسي بالقيمة النقدية المفتوحة (Reverse Monetary-to-Weight Selling)**: في العطارة المصرية والعربية، الزبون لا يقول دائماً «عايز 62.5 جرام فلفل أسود»، بل يقول: **«اديني بـ 20 جنيه فلفل أسود وبـ 15 جنيه كمون مطحون وبـ 10 جنيه كزبرة»**! أنظمة POS التقليدية تتجمد أمام هذا الطلب. أما في هارنيس «وكيل»، فبمجرد سماع «بـ 20 جنيه فلفل أسود»، يستدعي المحرك الحتمي سعر الكيلو الحالي (مثلاً 400 جنيه/كجم)، ويحسب الوزن العكسي تلقائياً: الوزن المطلوب بالجرام = (20 جنيه ÷ 400 جنيه للكيلو) × 1000 = 50 جراماً بالضبط فيسجل إيراداً بقيمة 20 جنيهاً، ويخصم 50 جراماً بالضبط من جوال الفلفل الأسود المفتوح، بل ويعرض للعطار فوق البطاقة: ⚖️ اوزن 50 جرام للزبون!

2. **التصنيع الخفيف والخلطات السرية (Micro-BOM & Recipe Blending)**: العطار يشتري التوابل خاماً بالحصى (شيكارة 25 كيلو أو 50 كيلو)، ثم يطحن جزءاً منها، أو يصنع «خلطة السبع بهارات» أو «تحويجة البن المحوج بالحبهان وجوزة الطيب». يوفر «وكيل» أداة `record_blend_production` التي تسمح للعطار أن يقول: «عملت النهارده 10 كيلو خلطة بهارات كبسة»، فيقوم «وكيل» تلقائياً بخصم المكونات السبعة بنسبها المسجلة في ذاكرة المحل (`BUSINESS_DNA`)، وإضافة نسبة هالك الطحن والغربلة (مثلاً 2% تطاير ورطوبة)، وإضافة 10 كيلو جاهزة للبيع بسعر تكلفتها الحقيقي الموزون!

3. **معالجة الهالك الطبيعي وتقشير الأوزان (Natural Shrinkage & Scale Tolerance)**: التوابل والأعشاب تفقد جزءاً من وزنها بسبب الجفاف أو التطاير أو بقايا قاع الشيكارة (التراب والحصى بعد الغربلة). يتيح «وكيل» عند إغلاق الشيكارة («الشيكارة دي خلصت») حساب الفرق بين الوزن المشترى (25 كجم) وإجمالي المباع الفعلي (24.4 كجم)، وتسجيل الـ 600 جرام كـ «هالك طبيعي مسموح به (2.4%)» ضمن تكلفة البضاعة المباعة، مع تنبيه المالك فقط إذا تجاوز الهالك النسبة الطبيعية (مما يكشف السرقة أو الإهمال).

ثالثاً: قطاع السوبر ماركت والبقالة (Supermarkets & Groceries) — كشكول الشكك ومرتجعات الموردين اليومية

توضح المصادر المتخصصة في إدارة البقالات والسوبر ماركت في مصر والسعودية مثل إدارة حسابات السوبر ماركت وبرنامج سيلزكس للسوبر ماركت أن عصب السوبر ماركت الشعبي والمتوسط يدور حول أربع عمليات يومية عالية التكرار:

1. **إدارة «كشكول الشكك» العائلي (Household Credit Ledger)**: في الأحياء السكنية، الحساب لا يكون باسم شخص واحد، بل باسم «البيت» أو «الأسرة» (حساب الحاج محمود الدور التالت: يسحب منه الحاج محمود، أو زوجته، أو ابنه الصغير، أو عبر التليفون للدليفري). يدعم «وكيل» ربط **الأشخاص المفوضين بالسحب** تحت حساب عائلي واحد، مع تسجيل «مين اللي استلم الطلب والساعة كام» في كل حركة («ابن مدام منى خد طلبات بـ 85 جنيه على حساب البيت»)، وإصدار كشف حساب واتساب نظيف ومفصل باليوم والساعة في أول الشهر يمنع أي جدال أو إنكار من العميل.

2. **معالجة أزمة «الفكة» والباقي المؤجل (Micro-Change Credit / Debit)**: تتكرر يومياً جملة: «الحساب 195 جنيه، الزبون اداني 200 ومفيش فكة، قولتله ليك 5 جنيه المرة الجاية». في «وكيل»، تُسجل هذه الحركة بأمر واحد كـ «رصيد دائن صغير

للعميل (فكة مؤجلة: 5 جنيه)» يظهر تلقائياً كتذكير عند أول زيارة قادمة للعميل!

3. **دورة الموردين اليوميين والتبديل المباشر (Daily Van-Sales & Instant Spoilage Swap)**: مناديب الألبان والزبادي والعيش والبيض والشيبسي يمرون يومياً؛ يأخذون العلب المنتهية الصلاحية أو المكسورة (مرتجع تالف)، وينزلون بضاعة جديدة، ويأخذون دفعة نقدية على الواقف. يوفر «وكيل» أداة موحدة `record_daily_supplier_visit` تنفذ الثلاث حركات (استلام جديد + خصم مرتجع تالف + صرف نقدية) في قيد مركب واحد خلال 3 ثوانٍ.

رابعاً: قطاع الجيمات والنوادي الرياضية (Gyms & Fitness Studios) — التجميد والحضور وعمولات المدربين

تُبين المنصات المتخصصة في إدارة النوادي الرياضية في مصر والسعودية مثل نظام سجل ERP لإدارة الجيمات وبرنامج جيماوي ومنصة eClubs السعودية أن إدارة الجيم تختلف جذرياً عن بيع السلع لأنها تدير «حق انتفاع زمني ومكاني وخدمي». ويجب أن يغطي هارنيس «وكيل» في وضع الجيم (`Gym Mode`) العمليات التالية بدقة:

1. **محرك قواعد الاشتراكات والتجميد والترقية (Membership Lifecycle, Freeze & Prorated Upgrade)**: عندما يقول موظف الاستقبال: «العضو كريم عادل عايز يجمد اشتراكه أسبوعين عشان مسافر»، يتحقق «وكيل» فوراً من شروط باقة العضو (هل باقته تسمح بالتجميد؟ كم رصيد أيام التجميد المتبقي له؟ هل توجد رسوم تجميد؟)، ثم يمدد تاريخ انتهاء الاشتراك تلقائياً بمقدار 14 يوماً. وإذا قال: «كريم عايز يرقي اشتراكه من شهري لـ 3 شهور»، يحسب «وكيل» قيمة الأيام المتبقية أو يدمج المدة ويطرح ما دفعه العضو سابقاً ليخرج صافي المبلغ المطلوب تحصيله فوراً.
2. **بوابة الدخول الذكية وتفسير سبب الرفض (Explainable Access Gate)**: عند مسح كارت العضو أو كتابة اسمه لتسجيل الحضور، يعرض «وكيل» إشارة ثلاثية واضحة: **أخضر** (دخول مسموح مع عرض الأيام المتبقية ودعوات الضيوف `Invitations` وفحوص `InBody` المتاحة)، أو **أصفر** (دخول مسموح مع تحذير: «عليه قسط متأخر بـ 300 جنيه مستحق من يومين» أو «فاضل 3 أيام في الاشتراك»)، أو **أحمر** (مرفوض مع السبب الدقيق: «الاشتراك مجمد حالياً» أو «تجاوز مواعيد دخول الفترة الصباحية»)، مع إتاحة زر «سماح استثنائي بسبب» للمدير يُسجل في دفتر الرقابة.
3. **إدارة التدريب الشخصي (PT) واستحقاق العمولات بالتنفيذ لا بالبيع (Session-Based PT Commission Accrual)**: أكبر خطأ مالي في الجيمات هو صرف عمولة الكابتن كاملة فور بيع باقة الـ PT (مثلاً 12 حصة بـ 3000 جنيه)، ثم يلغي المشترك الباقة أو يترك الكابتن الجيم! يفصل «وكيل» بين «تحصيل قيمة باقة PT» وبين «استحقاق عمولة المدرب»: فكلما قال الكابتن أو موظف الاستقبال «كابتن عمر خلص حصة PT مع العضو أحمد»، يخصم «وكيل» حصة من رصيد العضو (يتبقى 11/12)، ويُرحل عمولة هذه الحصة فقط (مثلاً 75 جنيهاً) إلى حساب مستحقات الكابتن عمر لصرفها مع الراتب أو أسبوعياً.

القطاع التجاري	أهم 3 أوامر يومية بالعامية يفهمها «وكيل»	الحسابات والقيود الخلفية التي يجريها الهارنيس تلقائياً	القيمة المضافة على الدفتر الورقي
الصيدليات	«بعت شريطين أوجمنتين 1جم»، «سجل نيكسيوم 40 في النواقص»، «طلعلي الأدوية اللي هتنتهي قبل شهر 12»	خصم جزئي بالوحدة الصغرى، مطابقة التشغيلة الأقرب انتهاءً (FEFO)، اقتراح البديل بنفس المادة الفعالة، تجميع طلبية المخزن	منع خسائر منتهي الصلاحية، عدم ضياع مبيعات النواقص، ضبط فروق التسعير القديم والجديد
العطارة والمحامص	«بـ 15 جنيه كمون وبـ 20 فلفل أسود»، «عملت 5 كيلو تحويجة بن مخصوص»، «جوال اللوز الـ 10 كيلو خلص»	حساب الوزن العكسي بالجرام من المبلغ النقدي، خصم مقادير الخلطة (BOM) من الأصناف الخام، حساب نسبة الهالك الطبيعي والغربلة	حل معضلة البيع بمبالغ مفتوحة، معرفة التكلفة الحقيقية للخلطات، كشف الهالك غير الطبيعي
السوبر ماركت والبقالة	«ابن مدام سعاد خد طلبات بـ 110 على الحساب»، «ليه 5 جنيه باقي فكة»، «مندوب المراعي نزل 20 زبادي وخد 3 تالف»	قيد على الحساب العائلي مع اسم المستلم، تسجيل رصيد فكة دائن يظهر في الزيارة القادمة، قيد مركب للتوريد والمرتجع والدفعة	القضاء على ضياع ونكران كشكول الشكك، ضبط حسابات الفكة، تسوية الموردين اليوميين في ثوانٍ
الجيمات والنوادي	«جمد اشتراك أحمد سمير 10 أيام»، «محمد دفع 500 من قسط السنوي»، «كابتن طارق لعب حصة PT مع سارة»	التحقق من سقف التجميد وتمديد تاريخ الانتهاء، تحديث جدول الأقساط وحالة البوابة، خصم حصة PT وترحيل عمولة الجلسة للمدرب	منع التلاعب في مدد الاشتراك والتجميد، تحصيل الأقساط المتأخرة على البوابة، ربط عمولة المدرب بالحضور الفعلي

10. البنية الهندسية لبرومبت النظام الموحد (Unified System Prompt) ومحرك الحسابات الحتمي والبحث الشبكي

بناءً على الدروس المستخلصة من معمارية Pi ذات البرومبت الرشيق، وتحليل برومبت Claude، وقواعد التخزين المؤقت في DeepSeek، يجب ألا يُكتب الـ `Unified System Prompt` الخاص بـ «وكيل» كمقال طويل مليء بالحشو، بل كـ **عقد هندسي معياري من جزأين**: 1. **البادئة الثابتة غير المتغيرة (Byte-Identical Cached Prefix — ~750 Tokens)**: لا تتغير أبداً بين الطلبات لضمان 85%+ Cache Hit وسرعة استجابة فائقة. 2. **الذيل السياقي الديناميكي (Dynamic Runtime Tail — ~250 Tokens)**: يُحقن في آخر رسالة قبل طلب المستخدم مباشرة، ويحتوي على دستور المنشأة النشط، والكيانات المستخرجة استباقياً، وحالة الواجهة الحالية، والوقت المحلي.

الهيكل المرجعي لبرومبت النظام الموحد في «وكيل»

يوضح الجدول المعماري التالي التصميم الدقيق لطبقات البرومبت الموحد بترتيبها الإلزامي داخل مصفوفة الرسائل (`messages`):

الترتيب والموقع	اسم الكتلة في السياق	قابلية التخزين المؤقت (Cache)	المحتوى الهندسي والقواعد الصارمة المضمنة في الكتلة
الكتلة 1 (System Prefix)	`CORE_IDENTITY_AND_INVARIANTS`	**ثابتة 100% (Cached)**	تعريف هوية «وكيل» كموظف محاسبي وتشغيلي، قاعدة منع اختراع الأرقام، قاعدة الاعتماد الحصري على محرك الحسابات الحتمي، قاعدة الإيجاز المهني باللهجة المحلية
الكتلة 2 (System Prefix)	`MEMORY_AND_UI_PROTOCOL`	**ثابتة 100% (Cached)**	متى يستدعي الموديل أدوات الذاكرة (`memory_upsert_rule`, `lexicon_learn_alias`, `skill_propose`)، ومتى يستدعي أدوات التحكم في الواجهة (`ui_navigate`, `ui_render_card`)، وقواعد تفكيك المهام المركبة
الكتلة 3 (Tools Array)	`DETERMINISTIC_SORTED_TOOLS`	**ثابتة 100% (Cached)**	تعريفات الأدوات الأساسية مرتبة أبجدياً بمفاتيح JSON ثابتة (`strict: true`)، مع إبقاء تفاصيل المهارات الفرعية خارج التعريف الأساسي لجلبها عبر `skill_read`
الكتلة 4 (System/Context)	`TENANT_BUSINESS_DNA`	**شبه ثابتة لكل منشأة (Cached per Tenant)**	محتوى ملف `BUSINESS_DNA.md` الخاص بالمحل (نوع النشاط: صيدلية/عطارة/سوبرماركت/جيم، العملة، القواعد الخاصة التي علمها المالك لوكيل، فهرس عناوين المهارات المفعلة)
الكتلة 5 (Dynamic Tail)	`LIVE_RUNTIME_STATE`	**متغيرة لكل طلب (Uncached Tail)**	التوقيت المحلي للمنشأة، اسم ودور الموظف الحالي (`Owner` / `Cashier` / `Reception`)، الشاشة المفتوحة حالياً في التطبيق، الكيانات المطابقة استباقياً من قاعدة البيانات (`Prefetched Entities`)

وفيما يلي النص الهندسي المعياري للبادئة الثابتة (`CORE_IDENTITY_AND_INVARIANTS + MEMORY_AND_UI_PROTOCOL`) المصمم ليعمل بأعلى كفاءة مع أي موديل (سواء كان DeepSeek أو Claude أو GPT أو Qwen أو Llama):

النص المرجعي لنواة برومبت النظام الموحد (`WAKIL_UNIFIED_SYSTEM_PROMPT_V2`):

أنت «وكيل» (Wakil)، الموظف المحاسبي والتشغيلي الذكي المسؤول عن إدارة النشاط التجاري وصيانة سجلاته المالية والمخزنية والخدمية بدقة حتمية.

1. القواعد المحاسبية الحتمية (Zero-Hallucination Financial Rules): - لا تحسب المجاميع أو الضرائب أو الأوزان العكسية أو الأرصدة بتخمينك اللغوي أبداً؛ مرر المعاملات الخام دائماً إلى أدوات المجال أو أداة calc_decimal_engine واترك الخادم يجري الحسابات بالقرش والجرام. - لا تعلن إتمام أي عملية بيع أو تحصيل أو صرف أو تعديل مخزون أو اشتراك إلا بعد استدعاء الأداة المخصصة واستلام حالة SUCCEEDED أو DRAFT_CREATED من الخادم. - إذا كان اسم الصنف أو العميل أو المورد يحتمل أكثر من تطابق في قائمة الكيانات المستخرجة، أو كان هناك حقل جوهري ناقص، استدعِ أداة إنشاء المسودة التفاعلية واسأل المستخدم سؤالاً واحداً مباشراً وواضحاً.

2. بروتوكول الذاكرة الحية والتطور الذاتي (Active Memory & Self-Improvement Protocol): - أنت موظف يتعلم باستمرار ولا ينسى تعليمات صاحب العمل. عندما يخبرك المستخدم بقاعدة عمل دائمة، أو سقف آجل لعميل، أو سياسة تسعير/تجميد/خصم، استدعِ فوراً أداة memory_upsert_rule لحفظها في دستور المنشأة. - عندما يستخدم المستخدم اسماً دارجاً أو مختصراً أو لقباً لصنف أو عميل أو مورد ويتأكد المقصود منه، استدعِ أداة lexicon_learn_alias في نفس الجولة لتربط الاسم الدارج بالمعرف الرسمي نهائياً. - عندما تلاحظ تكرار سلسلة خطوات يدوية من المستخدم، اقترح تحويلها إلى اختصار وتشغيل آلي عبر أداة skill_propose.

3. بروتوكول تفكيك المهام والتحكم الكامل في التطبيق (Task DAG & Full App Control): - إذا تضمنت رسالة المستخدم أكثر من عملية واحدة، قسمها فوراً عبر plan_create_task_list ونفذ كل خطوة مستقلة بأداتها الخاصة دون أن تعطل الخطوات الواضحة بسبب خطوة واحدة تحتاج استفساراً. - أنت تتحكم في واجهة التطبيق بالكامل: استخدم ui_navigate_and_filter وui_render_generative_card وui_prefill_and_stage_form لعرض الجداول والبطاقات وفتح الشاشات المناسبة للمستخدم بدلاً من سرد الجداول الطويلة نصياً.

4. أسلوب التواصل المهني (Egyptian/Arabic SMB Register): - تحدث بلغة عربية عملية، دافئة، مختصرة جداً، ومباشرة تناسب بيئة السوق العربي. في العمليات الروتينية، اكتفِ بسطر تأكيد واحد يذكر الصنف والمبلغ والرصيد المحدث لأن بطاقة الواجهة تعرض كافة التفاصيل.

محرك الحسابات الحتمي (Deterministic Decimal & Unit Engine)

لماذا تخطئ النماذج اللغوية أحياناً في ضرب 17.35 × 14 أو حساب خصم 13.5% على 12 صنفاً في فاتورة صيدلية؟ لأن النماذج تتنبأ بالتوكن التالي ولا تنفذ عمليات حسابية في وحدة المعالجة المركزية (ALU). في هارنيس «وكيل»، **يُمنع النموذج من إجراء الحسابات المالية بنفسه**؛ بل يمرر المدخلات الخام إلى طبقة الحسابات الحتمية في الخادم: - في العطارة، يرسل الموديل: {item_id: "sp_12", requested_money_egp: 15}، فيتولى كود الخادم المكتوب بـ Decimal (بدقة 4 خانات عشرية للوزن وقرش صحيح للمال) استرجاع سعر الكيلو وحساب الجرامات بدقة 100% وإرجاع النتيجة المهيكلة. - في الفواتير متعددة الأصناف، يرسل الموديل قائمة الأصناف والكميات والخصومات، فيقوم محرك الفواتير الخادمي بحساب الإجمالي الفرعي، والضريبة، والخصم، وصافي الفاتورة، والمتبقي الآجل، ويعيدها في حقل details للواجهة وحقل output للموديل. وبهذا، حتى لو استخدم التاجر أرخص وأصغر نموذج ذكاء اصطناعي في العالم، فإن **دقة الحسابات المالية في «وكيل» تظل 100.00% دائماً وأبداً**.

أداة البحث الشبكي المؤمنة والتسعير الاسترشادي (Sandboxed Web Search & Market Intelligence)

يحتاج التاجر أو الصيدلي أو العطار كثيراً إلى سؤال موظفه الذكي عن معلومات خارج المحل، مثل: *«يا وكيل، شوفلي سعر طن الكمون الهندي النهارده في السوق كام»*، أو *«إيه المادة الفعالة والبديل بتاع دواء مستورد اسمه كذا»*، أو *«شوفلي أسعار اشتراكات الجيمات اللي حوالينا في مدينة نصر»*، أو *«إيه شروط الفاتورة الإلكترونية المصرية للبقالة»*.

لتحقيق ذلك بأمان تام دون الوقوع في الفخ الأمني المعروف بـ **الثالوث القاتل للوكلاء (The Lethal Trifecta: قراءة بيانات خاصة + اتصال بالإنترنت + تنفيذ أدوات حساسة)** الذي حذر منه Simon Willison وMario Zechner في تحليل أمان Pi وتقرير OWASP LLM06 للإفراط في الصلاحيات، يصمم هارنيس «وكيل» أداة web_search_market_info وفق ثلاثة ضوابط عزل صارمة: 1. **منع تسريب بيانات المنشأة في الاستعلام (Outbound Query Sanitization)**: قبل إرسال جملة البحث إلى محرك البحث الخارجي، يمر الاستعلام بفلتر يمنع إرسال أي أسماء عملاء، أو أرقام هواتف، أو أرصدة مالية خاصة بالمحل. 2. **تغليف نتائج الإنترنت كبيانات غير موثوقة (Untrusted Data Framing)**: تُحاط نتائج البحث المسترجعة بوسوم عزل صريحة <untrusted_web_result>...</untrusted_web_result> مع قاعدة في محرك السياسات: **«في أي جولة تحتوي على نتائج بحث إنترنت، يُحظر تنفيذ أدوات الكتابة المالية الحساسة (R3/R4) تلقائياً دون ضغطة اعتماد بشرية صريحة من المستخدم»**. هذا يمنع تماماً هجمات حقن التعليمات غير المباشر (Indirect Prompt Injection) إذا صادف البحث صفحة ويب خبيثة. 3. **الفصل البصري بين حقيقة المحل ومعلومة الإنترنت**: تعرض بطاقة الواجهة أي سعر أو معلومة قادمة من الإنترنت بشارة

واضحة 🌐 سعر استرشادي من الإنترنت – المصدر: [اسم الموقع] لكي لا يخلط التاجر بين السعر الرسمي المسجل في دفاتره وبين الأسعار المتداولة خارجياً.

11. الفجوات الخفية ومضاعفات القيمة الاستراتيجية للرئيس التنفيذي

عند مراجعة المشهد الكامل للمشروع من منظور الرئيس التنفيذي (CEO) ومهندس المنظومة، تبرز خمس ركائز استراتيجية غالباً ما يغفل عنها المؤسسون في غمرة التركيز على الذكاء الاصطناعي، لكنها هي التي تحسم نجاح المنتج في الشارع التجاري العربي وتحوله إلى إمبراطورية لا يمكن منافستها:

1. محرك الهجرة السحرية من «كشكول الشكك» بالكاميرا والصوت (Zero-Friction Paper-to-Agent Onboarding)

السبب الأول لرفض صاحب البقالة أو العطارة أو الصيدلية أو الجيم لأي نظام جديد هو سؤال: «*طب والحسابات القديمة والـ 200 زبون اللي مكتوبين في الكشكول عندي؟ هقعد أكتبهم واحد واحد؟*». إذا طلب «وكيل» من التاجر إدخال بياناته يدوياً في أول يوم، فسنخسر 80% من العملاء في أول ساعة. **الحل المبتكر في هارنيس «وكيل»**: ميزة **«صوّر كشكولك وابدأ فوراً» (Snap-the-Notebook Onboarding)**. يفتح التاجر كاميرا الموبايل من داخل «وكيل»، ويصور صفحات كشكول الآجل أو قائمة أسعار العطارة أو كشف أعضاء الجيم الورقي (أو يقرؤها بصوته في دقيقتين: «الحاج سعيد عليه 450، أم كريم عليها 210، محمد العطار ليه 3000...»). يقوم نموذج الرؤية (Vision LLM) داخل الهارنيس باستخراج كافة الأسماء والمبالغ والأصناف في جدول معاينة تفاعلي واحد، وبضغطة زر واحدة «اعتمد الأرصدة الافتتاحية»، يتحول الكشكول الورقي بالكامل إلى قاعدة بيانات رقمية موثقة في أقل من 3 دقائق!

2. وضع الصمود عند انقطاع الإنترنت والكهرباء (Local-First Offline Queue & Edge Fallback)

في مصر والعديد من الأسواق العربية، ينقطع الإنترنت أو تضعف الشبكة داخل المحلات الأرضية والمخازن، وقد تنقطع الكهرباء. إذا توقف «وكيل» عن العمل لأن الإنترنت ضعيف، سيعود التاجر فوراً للورقة والقلم! **الحل المعماري**: بناء واجهة «وكيل» كتطبيق ويب تقدمي محلي أولاً (Local-First PWA with IndexedDB / OPFS SQLite): - يتم تخزين قائمة الأصناف وأسعارها وأرصدة العملاء الحالية محلياً على هاتف أو تابلت التاجر وتحديثها باستمرار (Delta Sync). - عند انقطاع الإنترنت، يعمل **المحلل المحلي الخفيف (Offline Deterministic & Tiny Regex Parser)** المدمج في المتصفح ليلتقط الأوامر الأساسية («بيع 2 لبن بـ 80»، «تحصيل 200 من أحمد») أو يفتح بطاقة الإدخال السريع بلمسة واحدة، ويحفظ المعاملات والصوتيات المسجلة في **طابور محلي مشفر ومرتب زمنياً (Signed Local Outbox Queue)** مع مفتاح `idempotency_key` فريد لكل حركة. - بمجرد عودة الاتصال، يرسل الهارنيس الطابور إلى الخادم لمعالجة التسويات والرسائل الصوتية المتراكمة دون ضياع قرش واحد.

3. رادار كشف التلاعب والسرقة الخفية للمالك فقط (Silent Shrinkage & Fraud Radar)

أكبر ألم يؤرق صاحب الصيدلية أو السوبر ماركت أو الجيم عندما يغيب عن المحل ويترك الكاشير أو الموظف هو السؤال: «*هل الموظف بيسجل كل حاجة بجد ولا بيلعب في الحسابات؟*». يوفر «وكيل» ميزة حصرية للمالك وحده تسمى **«رادار الأمانة السري» (Owner Eyes-Only Anomaly Digest)**، وهي مهارة خلفية تراقب سجل الأحداث غير القابل للمحو (`Immutable Audit Events`) وتكشف الأنماط المريبة التي لا ينتبه إليها البشر: - كاشير يقوم بإلغاء أو عكس الفواتير بعد خروج الزبون بدقائق (خاصة في أوقات غياب المالك). - استعلام متكرر عن سعر صنف عبر «وكيل» دون تسجيل بيع له (إشارة على البيع خارج النظام ووضع المال في الجيب). - موظف استقبال في الجيم يسجل «سماح دخول استثنائي» لأصدقاء أو أعضاء منتهية اشتراكاتهم بشكل متكرر. - فروق متكررة في تسويات العطارة أو عجز الدرج في وردية موظف بعينه دون غيره. يرسل «وكيل» هذه الملاحظات بهدوء وحيادية في ملخص خاص للمالك فقط مع روابط للأدلة الزمنية: «*تنبيه رقابي: في وردية المساء أمس، تم عكس 4 عمليات بيع نقدي بإجمالي 620 جنيه بعد تسجيلها بـ 10 دقائق — اضغط لمراجعة السجل*». هذه الميزة وحدها كفيلة بجعل صاحب العمل يدفع اشتراك «وكيل» وهو مغمض العينين لأن النظام يوفر له ثمن كاميرات مراقبة ومحاسب مراجعة داخلي!

4. جسر الواتساب والمندوبين المحكوم بالاعتماد (Controlled WhatsApp Business Loop)

التجارة الصغيرة في العالم العربي تعيش داخل تطبيق WhatsApp. بدلاً من محاولة إجبار عملاء الجيم أو موردي الصيدلية على تحميل تطبيق خاص بهم، يمتلك «وكيل» أداة `stage_whatsapp_message` (مصنفة ضمن المستوى R3/R4 حسب العدد): - عندما يسدد عميل دفعة من حساب «الشكك»، يجهز «وكيل» رسالة إيصال أنيقة بضغطة زر واحدة لإرسالها له عبر واتساب: «*تم استلام 300 ج من حسابكم لدى سوبر ماركت البركة، الرصيد المتبقي 150 ج — شكراً لتعاملكم*» (وهو ما يخلق رقابة مزدوجة تمنع الكاشير من أخذ المال دون تسجيله لأن العميل ينتظر رسالة الإيصال!). - في الجيم، يجهز «وكيل» قائمة بالأعضاء الذين سينتهي اشتراكهم خلال 3 أيام، ويعرض على المالك بطاقة واحدة: «*عندك 9 أعضاء اشتراكهم هيخلص الخميس، جهزتلهم رسائل تذكير باسم كل واحد.. أرسلهم دلوقتي؟*».

5. اقتصاديات الوحدة وحماية هامش الربح (Token Unit Economics & Margin Shield)

إذا كان صاحب البقالة يدفع اشتراكاً شهرياً لـ «وكيل» قدره مثلاً 300 أو 500 جنيه مصري (أو 50 ريالاً سعودياً)، ويجري 400 عملية يومياً (12,000 عملية شهرياً)، فكيف نضمن ألا تلتهم تكلفة الـ API الخاصة بالنماذج اللغوية كامل إيراد الاشتراك؟ - أولاً: بفضل **وضع BYOK (أحضر مفتاحك الخاص)**، يمكن للعملاء المتقدمين أو الشركاء ربط مفاتيحهم مباشرة، وتكون تكلفة الـ Tokens على حسابهم بالكامل بينما يبيع «وكيل» قيمة الهارنيس والنظام السحابي. - ثانياً: في الباقات المدارة شاملة الذكاء الاصطناعي (Managed AI Plans)، وبفضل **التوجيه الهجين (Agentic Routing)** + **كاش البادئة بنسبة 80%** (**DeepSeek V3.2 بتكلفة $0.06 للمليون توكن كاش**) + **فصل مخرجات الأدوات (output) قصير للموديل**: فإن العملية الواحدة تستهلك في المتوسط ~800 توكن كاش ($0.000048) + ~150 توكن جديد ($0.000043) + ~60 توكن مخرجات ($0.000025) = **أقل من $0.00012 للعملية الواحدة**! أي أن 12,000 عملية كاملة في الشهر تكلف أقل من **1.44 دولار أمريكي** فقط! هذا يمنح الشركة هامش ربح إجمالي (Gross Margin) يتجاوز 80% إلى 85% على مستوى البرمجيات كخدمة (SaaS).

12. التوصيات التنفيذية وخارطة التطبيق المرحلية

لتحويل هذه الدراسة المعمارية إلى واقع ملموس داخل الكود الحالي لمنظومة «وكيل» دون تعطيل مسار الإطلاق أو هدم ما تم إنجازه، يُوصى باتباع خطة تنفيذ هندسية من أربع مراحل متتابعة ومحددة المخرجات:

المرحلة التنفيذية	الإطار الزمني المقترح	المخرجات الهندسية المحددة (Deliverables)	معيار التحقق والنجاح (Verification Gate)
المرحلة 1: ترقية بوابة النماذج وفصل مخرجات الأدوات	الأسابيع 1 – 2	بناء محول البروتوكولات الأربعة (`BYOK Adapter`)، إضافة فاحص القدرات التلقائي، تعديل `Typed Tool Registry` ليعيد `{output, details}`، وتثبيت البادئة لضمان الـ Prompt Caching	نجاح تشغيل نفس الجلسة بالتبادل بين DeepSeek وClaude وGemini ونماذج Ollama محلي مع تحقيق نسبة كاش >75%
المرحلة 2: منظومة الذاكرة الحية والمحلل الاستباقي	الأسابيع 3 – 4	إطلاق جدول/ملف `BUSINESS_DNA`، بناء الفهرس السريع للقاموس الدلالي (`LEXICON_GRAPH`) مع الجلب الاستباقي في <20ms، وتفعيل أدوات `memory_upsert_rule` و`lexicon_learn_alias`	قدرة «وكيل» على تعلم اسم دارج لصنف أو قاعدة خصم من جملة واحدة وتطبيقها في الجولة التالية في أقل من 600ms
المرحلة 3: تفكيك المهام والتحكم في الواجهة والـ HITL	الأسابيع 5 – 6	بناء محرك `plan_create_task_list` للأوامر المركبة، ربط الواجهة ببروتوكول أحداث AG-UI وأدوات `ui_*`، وتطبيق بطاقات المسودة والتنفيذ المتفائل المزود بزر تراجع	تنفيذ أمر مركب من 4 حركات مختلفة في رسالة واحدة مع تحديث الواجهة لحظياً أثناء تدفق الـ Partial JSON
المرحلة 4: حزم القطاعات الأربعة والرادار الرقابي والـ Offline	الأسابيع 7 – 10	تفعيل مهارات وأدوات الصيدليات (FEFO/تجزئة/نواقص)، والعطارة (بيع عكسي بالقيمة/خلطات/هالك)، والسوبرماركت (الشكك/الفكة)، والجيمات (تجميد/PT)، مع ميزة تصوير الكشكول وطابور Offline	نجاح تجربة ميدانية حية في محل عطارة وسوبر ماركت وجيم وصيدلية مع استيراد كشكول ورقي حقيقي في أقل من 5 دقائق

تؤكد هذه الخارطة أن مستقبل برمجيات الأعمال الصغيرة في العالم العربي لن يكون للأنظمة التي تضيف المزيد من القوائم والتقارير المعقدة، بل للمنظومة التي تخفي التعقيد المحاسبي بالكامل خلف موظف ذكي، سريع، أمين، يتحدث لغة السوق، ويتذكر كل تفصيلة، ويبني حول صاحبه نظام تشغيل يتطور ذاتياً كل يوم.

13. المراجع والمصادر الموثقة

1. Mario Zechner — What I learned building an opinionated and minimal coding agent (Pi Coding Agent Architecture)
2. Felipe Fontoura — Pi Coding Agent: 4 Tools, a 150-Word System Prompt, No MCP
3. Composio Engineering — Pi vs OpenCode: Open-Source Agent Harness Comparison
4. Agent Safehouse — Pi Coding Agent Sandbox & Context Files Analysis (`AGENTS.md` / `SKILL.md`)

5. DeepSeek Official API Docs — Tool Calls, Strict JSON Schema Mode & Thinking Mode
6. DeepSeek Official API Docs — Responses API & Mid-Conversation Tool Insertion
7. Ofox AI Engineering — DeepSeek V3.2 Prompt Caching Setup & Prefix Optimization (80% Savings)
8. TokenMix Engineering — DeepSeek's Response API vs OpenAI Responses & Reasoning Parser Architecture
9. Shlok Khemani — ChatGPT Memory and the Bitter Lesson: Reverse-Engineering the 4 Memory Layers
10. Simon Willison — Comparing the Memory Implementations of Claude and ChatGPT (`conversation_search` & `recent_chats`)
11. Drew Breunig — Claude's System Prompt: Chatbots Are More Than Just Models (16,739-Word Prompt Teardown)
12. AI UX Playground — What is Human-in-the-Loop UX? A 2026 Guide with ChatGPT, Gemini & Perplexity Examples
13. AI UX Playground — Chat Artifacts UX Pattern & Lifecycle States
14. AG-UI Protocol — Agent User Interaction Protocol Overview & Event Architecture
15. Promptessor — AI Agent Harness: Architecture, Execution Loops, Context, Memory & Permissions
16. Scalekit Engineering — Human-in-the-Loop Tool Calling: Approval Gates for AI Agents
17. arXiv — Agentic Routing: The Harness-Native Data Flywheel
18. UK AISI Inspect AI — Model Providers & Tool Emulation for OpenAI-Compatible Endpoints
19. OpenAI Developer Docs — Prompt Caching Architecture & Prefix Matching
20. Shopify Help Center — Shopify Sidekick AI Assistant Capabilities & Review Workflow
21. Loyverse POS — Point of Sale, Offline Sales & Inventory Features
22. Daftra ERP — Plans and Modules for Retail, Inventory & Accounting
23. PosMasr — Connect AI & Read-Only Scoped MCP Integration
24. فارماكير (Pharmacare) — المشاكل التي تواجه صيدليتك وإدارة تواريخ الصلاحية والمخزون
25. ميدكاكير (Medicakare) — 10 مشكلات تواجه الصيدليات ومخازن الأدوية وتعدد التشغيلات
26. ديكسيف (DEXEF) — برنامج محاسبة محلات العطارة لإدارة الأوزان والمخزون وتعدد الوحدات
27. البدر للمبيعات — برنامج كاشير محلات العطارة وإدارة الأصناف والميزان والنواقص
28. سِجِلّ (Seggel ERP) — برنامج إدارة الجيمات والنوادي الرياضية: الاشتراكات والتجميد والدخول والـ PT
29. جيماوي (Gymmawy) — نظام إدارة الجيم وتجميد الاشتراكات والحجوزات
30. سيلزكس (Salesics) — برنامج كاشير للسوبر ماركت وإدارة مبيعات محلات البقالة